

# GEORG-AUGUST-UNIVERSITÄT GÖTTINGEN

Uploaddatum: 20.04.2026

Uploadzeit: 13:49

**Dies ist ein von FlexNow automatisch beim Upload generiertes Deckblatt. Es dient dazu, die Arbeit automatisiert der Prüfungsakte zuordnen zu können.**

**This is a machine generated frontpage added by FlexNow.  
Its purpose is to link your upload to your examination file.**

Matrikelnummer: 21568978



# **Vorhersage von Toren im europäischen Fußball mithilfe PCA-basierter Indikatoren taktischer Spielstile und modellbasierten Gradientenboostings**

12-Wochen-Abschlussarbeit zur Erlangung des akademischen Grades  
„Bachelor of Arts“ an der Wirtschaftswissenschaftlichen Fakultät  
der Georg-August-Universität Göttingen

vorgelegt am 20.04.2026

von

Niklas Rappe

aus Göttingen

Matrikelnummer: 21568978

Adresse: Weidenweg, 11a, 37124, Rosdorf

E-Mail: niklas.rappe@stud.uni-goettingen.de

Studiengang: Ostasienwissenschaft / Chinesisch als Fremdsprache &  
Volkswirtschaftslehre

1. Gutachter: Prof. Dr. Elisabeth Bergherr

2. Gutachter: Lars Knieper

# Abstract

Diese Arbeit untersucht, inwieweit sich die erzielte Toranzahl pro Team in den europäischen Top-5-Ligen auf Basis vor dem Spiel verfügbarer Informationen für spätere Saisons vorhersagen lässt. Ein Fokus liegt dabei auf der Frage, ob sich aus umfangreichen Spielberichtsstatistiken mittels Hauptkomponentenanalyse (PCA) Indikatoren taktischer Spielstile konstruieren lassen, die einen Beitrag zur Torprognose leisten.

Die Datengrundlage umfasst 3.478 Spiele, sowie 143 erklärende Variablen. Für die Modellierung werden Informationen zur Teamstärke, Form, Kaderverfügbarkeit und zu PCA-basierten Spielstilmerkmalen kombiniert. Die Hauptkomponentenanalyse wird auf 302 Matchstatistiken angewendet und auf 21 Komponenten reduziert, die zusammen ca. 77 % der Gesamtvarianz erklären. Die Schätzung erfolgt mit einem Poisson-Modell im Rahmen des modellbasierten komponentenweisen Gradienten-Boostings unter Berücksichtigung team- und spielortbezogener Zufallseffekte mittels *mermboost*. Zur Evaluation wird ein zeitbasierter Trainings- und Testsplitt verwendet, bei dem die Saisons 2017/18 und 2018/19 zum Training und die Saison 2019/20 zur Prüfung der Vorhersagegüte dienen. Das finale Modell erreicht auf dem Testdatensatz einen RMSE von 1,156 und einen MAE von 0,891 und übertrifft damit eine Mittelwert-Baseline (RMSE: 1,259; MAE: 1,003). Aus den Torprognosen abgeleitete Spielausgänge werden mit einer *Accuracy* von 53,85 % vorhergesagt und liegen damit über einer Heimsieg-Baseline (45,21 %) sowie einer Marktwert-Baseline (49,95 %). Als relevante Einflussfaktoren erweisen sich Variablen zur Mittelfeld- und Offensivqualität, Formindikatoren sowie die Hauptkomponente *Spielkontrolle*.

Die Ergebnisse zeigen, dass die Vorhersage von Toren im Fußball auf Basis vor dem Spiel verfügbarer Informationen für spätere Saisons mit konkurrenzfähiger Güte möglich ist. Die Arbeit verdeutlicht, dass PCA-basierte Spielstilindikatoren einen inhaltlich interpretierbaren und empirisch nutzbaren Beitrag zur Modellierung leisten, auch wenn die insgesamt nur moderate Vorhersagegüte auf die weiterhin hohe Bedeutung situativer und zufallsbedingter Einflüsse im Fußball hinweist.

# Inhaltsverzeichnis

|                                                                     |             |
|---------------------------------------------------------------------|-------------|
| <b>Abstract</b>                                                     | <b>I</b>    |
| <b>1 Einleitung</b>                                                 | <b>1</b>    |
| <b>2 Datensatz und Feature-Engineering</b>                          | <b>3</b>    |
| 2.1 Ursprünglicher Datensatz . . . . .                              | 3           |
| 2.2 Konstruktion der Spielstilvariablen . . . . .                   | 4           |
| 2.3 Fehlende Schlüsselspieler . . . . .                             | 11          |
| 2.4 Finaler Modell-Datensatz . . . . .                              | 15          |
| <b>3 Methodik</b>                                                   | <b>16</b>   |
| 3.1 Modellbasiertes komponentenweises Gradienten-Boosting . . . . . | 17          |
| 3.2 Modellschätzung mittels Mermboost . . . . .                     | 19          |
| 3.3 Bestimmung der optimalen Stoppiteration . . . . .               | 21          |
| <b>4 Ergebnisse</b>                                                 | <b>23</b>   |
| <b>5 Diskussion</b>                                                 | <b>28</b>   |
| 5.1 Inhaltliche Interpretation der Ergebnisse . . . . .             | 28          |
| 5.2 Bewertung der konstruierten Variablen . . . . .                 | 29          |
| 5.3 Einordnung der Ergebnisse im Vergleich zur Literatur . . . . .  | 30          |
| 5.4 Limitationen und Ausblick . . . . .                             | 31          |
| <b>6 Fazit</b>                                                      | <b>33</b>   |
| <b>Literaturverzeichnis</b>                                         | <b>V</b>    |
| <b>7 Anhang</b>                                                     | <b>VIII</b> |
| 7.1 Spielerwerte (EA Sports FC) . . . . .                           | VIII        |
| 7.2 Übersicht der Skill-Matchups . . . . .                          | VIII        |
| 7.3 Beobachtete Formationen . . . . .                               | IX          |
| 7.4 FBref: Matchstatistiken . . . . .                               | X           |
| 7.5 Hauptkomponenten und Variablenladungen . . . . .                | XI          |
| 7.6 Aufschlüsselung der Positionsgruppen . . . . .                  | XIII        |
| 7.7 Korrelation im Datensatz . . . . .                              | XIII        |
| 7.8 Penalisierte Likelihood . . . . .                               | XIII        |

|                                   |             |
|-----------------------------------|-------------|
| 7.9 Zufällige Effekte . . . . .   | XIV         |
| 7.10 Korrelationsmatrix . . . . . | XVI         |
| <b>Abbildungsverzeichnis</b>      | <b>XVII</b> |

# 1 Einleitung

Fußball zählt weltweit zu den bedeutendsten und verbreitetsten Sportarten. Nach Angaben der FIFA gibt es weltweit rund fünf Milliarden Fußballfans, was die gesellschaftliche und wirtschaftliche Relevanz des Sports unterstreicht (FIFA, 2021). Gleichzeitig zeichnet sich Fußball durch eine vergleichsweise hohe Anzahl an Zufallsereignissen aus. So zeigen Wunderlich et al. (2021), dass die Torerzielung in erheblichem Maße von Zufallseinflüssen geprägt sein kann. Gerade diese Verbindung aus praktischer Relevanz und begrenzter Vorhersagbarkeit macht Fußball zu einem interessanten Anwendungsfeld statistischer und datengetriebener Modellierung.

Die wissenschaftliche Auseinandersetzung mit der Vorhersage von Fußballergebnissen hat eine lange Tradition. Einen frühen und bis heute einflussreichen Beitrag leisten Dixon and Coles (1997), die ein statistisches Modell zur Beschreibung von Fußballresultaten entwickeln. Neuere Überblicksarbeiten zeigen jedoch, dass die Prognose von Fußballergebnissen weiterhin ein methodisch anspruchsvolles Forschungsfeld darstellt. So kommen Hubáček et al. (2022) in ihrer experimentellen Übersicht zu score-basierten Vorhersagemodellen zu dem Ergebnis, dass sich viele etablierte Ansätze in ihrer Vorhersagegüte nur begrenzt unterscheiden. Gleichzeitig haben sich in den vergangenen Jahren zusätzliche leistungsbezogene Kennzahlen wie Expected Goals (xG) oder Expected Possession Value (EPV) etabliert, die neue Möglichkeiten für die Modellierung von Spielverläufen und Spielergebnissen eröffnen (Forcher et al., 2025).

Vor diesem Hintergrund untersucht die vorliegende Arbeit, inwieweit sich die erzielte Toranzahl pro Team in den europäischen Top-5-Ligen auf Basis vor dem Spiel verfügbarer Informationen für spätere Saisons vorhersagen lässt. Ein Fokus liegt dabei auf der Frage, ob sich aus Spielberichtsstatistiken mithilfe einer Hauptkomponentenanalyse Indikatoren taktischer Spielstile konstruieren lassen, die einen Beitrag zur Torprognose leisten. Ziel ist es somit, die Vorhersagegüte durch die Einbeziehung solcher Spielstilmerkmale zu verbessern und zugleich zu prüfen, inwieweit sich komplexe taktische und spielerische Merkmalsstrukturen in interpretierbare Hauptkomponenten überführen lassen. Die Ableitung des Spielausgangs aus den Torprognosen dient darüber hinaus der Einordnung und Vergleichbarkeit der Ergebnisse mit bestehender Literatur.

Aus dieser Fragestellung ergibt sich zugleich die methodische Vorgehensweise der Arbeit. Da die Toranzahl pro Team mithilfe vor dem Spiel verfügbarer Informationen vorhergesagt werden soll, werden zunächst geeignete Variablen aus ver-

schiedenen Datenquellen konstruiert. Hierzu zählen Maße der Mannschaftsqualität, Formindikatoren, Variablen zur Kaderverfügbarkeit sowie Spielstilmerkmale. Da die Spielberichtsstatistiken stark miteinander korreliert sind und in hoher Zahl vorliegen, werden diese mithilfe einer Hauptkomponentenanalyse zu Spielstilvariablen zusammengefasst. Auf dieser Grundlage wird anschließend ein Prognosemodell für die Toranzahl pro Team geschätzt, dessen Vorhersagegüte anhand geeigneter Gütemaße bewertet und dessen Einflussfaktoren inhaltlich interpretiert werden.

Die Arbeit ist wie folgt aufgebaut: Zunächst werden Datengrundlage und Variablenkonstruktion dargestellt. Anschließend wird die verwendete Methodik erläutert. Darauf aufbauend werden die Ergebnisse präsentiert und abschließend im Kontext bestehender Literatur diskutiert.

## 2 Datensatz und Feature-Engineering

Für die Prognose der erzielten Toranzahl pro Team werden aus verschiedenen Datenquellen vor dem Spiel verfügbare Variablen konstruiert. Im Folgenden werden die Datengrundlage sowie die einzelnen Schritte der Variablenkonstruktion für den finalen Modell-Datensatz beschrieben.

### 2.1 Ursprünglicher Datensatz

Die Grundlage der vorliegenden Arbeit bildet ein Datensatz, der Spielinformationen aus den Top-5-Ligen Europas umfasst. Zielvariable der Analyse ist die Anzahl der erzielten Tore pro Team und Spiel. Abbildung 1 zeigt die Verteilung dieser Zielvariable. Dabei wird deutlich, dass die Mehrheit der Beobachtungen im Bereich von 0 bis 2 Toren liegt, während höhere Toranzahlen seltener auftreten. Der Mittelwert der Toranzahl beträgt 1.39, während die Varianz bei 1.58 liegt. Die Varianz ist damit leicht größer als der Mittelwert, was auf eine geringe Überdispersion hindeutet. Insgesamt liegen beide Werte jedoch nah beieinander, sodass die Annahme eines Poisson-Modells zur Beschreibung der Toranzahl als angemessen erscheint (Fahrmeir et al., 2009).

Neben der Zielvariable umfasst der Datensatz eine Vielzahl erklärender Variablen, die sowohl team- als auch spielbezogene Informationen enthalten. Ein Bestandteil sind Leistungsindikatoren auf Basis von Spielerbewertungen aus der Fußballsimulation EA Sports FC (vormals FIFA), sowie Marktwerte, die von der Plattform (Transfermarkt GmbH & Co. KG, 2026) geschätzt werden.

Diese Kennzahlen wurden zunächst positionsspezifisch aggregiert, indem die Werte der Spieler innerhalb einer Mannschaft zu den Gruppen Torwart, Abwehr, Mittelfeld und Angriff zusammengefasst wurden. Dadurch wird die Teamstruktur abgebildet und gleichzeitig die Dimensionalität des Datensatzes reduziert. Eine detaillierte Übersicht der verwendeten Spielerwerte findet sich im Anhang (vgl. Abschnitt 7.1).

Anschließend wurden die aggregierten Kennzahlen standardisiert, um Unterschiede in den Skalen der Variablen zu berücksichtigen. Darauf aufbauend wurden logarithmierte Verhältnisse (Log-Ratios) zwischen ausgewählten Leistungskennzahlen beider Teams konstruiert, um relative Unterschiede in direkten Spielsituationen abzubilden. Dabei werden sowohl positionsspezifische Vergleiche innerhalb gleicher Mannschaftsteile (z. B. Mittelfeld gegen Mittelfeld) als auch positionsübergreifende Interaktionen zwischen unterschiedlichen Mannschaftsteilen (z. B. Angriff gegen geg-






Abbildung 1: Verteilung der erzielten Tore pro Spiel. Die Mehrheit der Beobachtungen liegt im Bereich von 0 bis 2 Toren, während höhere Toranzahlen seltener auftreten. Die rechtsschiefe Verteilung entspricht typischen Eigenschaften von Zähldaten und legt die Verwendung eines Poisson-Modells nahe.

nerische Abwehr) berücksichtigt. Zusätzlich werden einzelne Fähigkeitswerte wie Tempo, Abschlussstärke oder Passspiel in Relation zu defensiven Eigenschaften des Gegners gesetzt. Eine Übersicht befindet sich im Anhang (vgl. Abschnitt 7.2). Die so resultierenden Variablen ermöglichen eine Abbildung relativer Teamstärken, indem sie nicht nur die Gesamtqualität zweier Teams vergleichen, sondern gezielt positionsspezifische Interaktionen zwischen den Mannschaften erfassen.

Der ursprüngliche Datensatz enthielt zudem Informationen zu den gespielten Formationen der Teams. Da Formationen die tatsächliche Spielweise einer Mannschaft nur unzureichend abbilden, werden sie im weiteren Verlauf der Analyse nicht berücksichtigt. Stattdessen wird im folgenden Abschnitt ein datengetriebener Ansatz vorgestellt, der darauf abzielt, die Spielweise einer Mannschaft anhand einer Vielzahl von Matchstatistiken zu approximieren und in Form von übergeordneten Spielstilvariablen abzubilden.

## 2.2 Konstruktion der Spielstilvariablen

Taktische Entscheidungen spielen eine zentrale Rolle im modernen Fußball und beeinflussen maßgeblich die Entstehung von Torchancen und Toren. Die taktische Aus-

richtung einer Mannschaft lässt sich nicht allein durch die Wahl einer Formation beschreiben. Obwohl beispielsweise die Formation 4-2-3-1 mit 1.629 von insgesamt 6.956 Beobachtungen die am häufigsten verwendete Grundordnung im vorliegenden Datensatz darstellt (vgl. Anhang Abschnitt 7.3), können Teams mit derselben Formation sehr unterschiedliche Spielstile aufweisen. Die Formation selbst besitzt daher nur eine geringe Aussagekraft, wenn es darum geht, die Anzahl der Tore in einem Spiel vorherzusagen.

Aussagekräftiger wäre es beispielsweise zu wissen, ob eine Mannschaft regelmäßig einen Ballbesitzvorteil erspielt und dadurch häufiger zu Eckbällen und Torabschlüssen kommt. Andere Mannschaften könnten dagegen darauf spezialisiert sein, mit wenig Ballbesitz durch schnelles und direktes Passspiel ebenfalls viele Torabschlüsse zu generieren. Solche Eigenschaften lassen sich aus der Formation einer Mannschaft allein nicht ableiten. Daher wird in diesem Abschnitt ein datengetriebener Ansatz entwickelt, um diese Spielstileigenschaften zu approximieren und den ursprünglichen Datensatz entsprechend zu erweitern.

Dieser Ansatz soll auf Statistiken basieren, die nach Spielende im Spielbericht veröffentlicht werden. Zu diesen Statistiken zählen beispielsweise Passversuche, Ballbesitzanteile oder die Anzahl der Eckbälle und Torschüsse. Da viele dieser Variablen miteinander korreliert sind, oder sogar lineare Abhängigkeiten aufweisen (z. B. „Anzahl erfolgreicher Passversuche“ und „Anzahl an Passversuchen“), entsteht ein hochdimensionaler Datensatz, dessen direkte Analyse schwer ist. Die verwendeten Matchstatistiken wurden von FBref.com bezogen und zu einem Datensatz zusammengeführt. Vor Durchführung der PCA umfasste dieser Matchstatistik-Datensatz 302 Variablen pro Spiel. Eine vollständige Übersicht über die verwendeten Matchstatistiken findet sich im Anhang (vgl. Abschnitt 7.4).

Auch wenn die in dieser Arbeit verwendete Methode zur Vorhersage von Toren (modellbasiertes komponentenweises Gradienten-Boosting) grundsätzlich für hochdimensionale Datensätze geeignet ist und vergleichsweise robust gegenüber Multikollinearität ist (Mayr et al., 2014), ist eine vorherige Dimensionsreduktion dennoch sinnvoll, um die Vielzahl ähnlicher Variablen auf wenige interpretierbare Dimensionen zu reduzieren.

Ein verbreitetes Verfahren zur Dimensionsreduktion in diesem Kontext ist die *Principal Component Analysis* (PCA). Die PCA ermöglicht es, eine große Anzahl möglicherweise korrelierter Variablen durch eine kleinere Anzahl neuer orthogonaler Variablen zu ersetzen und dennoch den größten Teil der Varianz der ursprünglichen Daten zu erklären (James et al., 2021).

Zur Konstruktion der Hauptkomponenten werden die Variablen zunächst standardisiert, sodass sie vergleichbare Größenordnungen aufweisen und keine einzelne Variable aufgrund ihrer Skalierung dominiert. Anschließend wird eine lineare Kombination der ursprünglichen Variablen bestimmt, deren Varianz maximal ist. Diese lineare Kombination bildet die erste Hauptkomponente.

Formal ist jede Hauptkomponente  $Z_j$  eine lineare Kombination der ursprünglichen Variablen  $X_1, \dots, X_p$ :

$$Z_j = \sum_{i=1}^p \phi_{ij} X_i, \quad j = 1, \dots, p \quad (1)$$

Die Gewichtungskoeffizienten  $\phi_{ij}$  (sogenannte Ladungen) werden dabei so gewählt, dass die Varianz der resultierenden Variable maximiert wird. Um eine eindeutige Lösung zu gewährleisten, unterliegen die Koeffizienten einer Normierungsbedingung, sodass die Summe ihrer quadrierten Werte gleich eins ist (James et al., 2021).

Weitere Hauptkomponenten werden unter der Nebenbedingung bestimmt, dass sie orthogonal zu den bereits bestimmten Komponenten sind und ebenfalls möglichst viel verbleibende Varianz erklären. Auf diese Weise entsteht eine Folge von Komponenten, die sukzessive die Struktur der Daten erfassen.

Durch diese Transformation kann ein Datensatz mit vielen Variablen auf eine kleinere Anzahl interpretierbarer Dimensionen reduziert werden (James et al., 2021). Aus geometrischer Sicht entsprechen die Hauptkomponenten Richtungen im Variablenraum, entlang derer die Varianz der projizierten Daten maximiert wird (Hastie et al., 2009). Dabei ist zu beachten, dass das Vorzeichen der Hauptkomponenten keine inhaltliche Bedeutung besitzt, da sowohl eine Richtung als auch ihre entgegengesetzte Richtung dieselbe Varianz erklären.

Die durch die PCA bestimmten Ladungen geben an, mit welchem Gewicht die einzelnen Variablen in eine Hauptkomponente eingehen. Für jede Mannschaft wird der Wert einer Hauptkomponente berechnet, indem die standardisierten Variablenwerte mit diesen Gewichten multipliziert und anschließend aufsummiert werden. Variablen mit starken Ausprägungen und gleichzeitig hohen (positiven oder negativen) Ladungen haben somit einen besonders starken Einfluss auf den Wert der jeweiligen Hauptkomponente. Die Anzahl der berücksichtigten Hauptkomponenten wurde mithilfe des Kaiser-Kriteriums auf 21 festgelegt. Berücksichtigt werden alle Komponenten, deren Eigenwert größer als eins ist, da diese jeweils mehr Varianz erklären als eine einzelne standardisierte Ausgangsvariable (Everitt and Hothorn, 2011). Wie in Abbildung 2 dargestellt, erklären diese 21 Komponenten zusammen

ca. 77 % der Gesamtvarianz der Matchstatistiken. Den größten Beitrag leistet dabei die erste Hauptkomponente, die mit ca. 27 % den höchsten Anteil der Varianz erklärt.




Abbildung 2: Erklärte und kumulierte Varianz der Hauptkomponenten. Die ersten 21 Komponenten erfassen etwa 77 % der Gesamtvarianz der verwendeten Matchstatistiken.

Die Abbildung 3 zeigt die durchschnittlichen Werte der ersten drei Hauptkomponenten *Spielkontrolle*, *Defensivintensität* und *Spielbalance* für jeweils den Meister (blau), ein Team aus dem Tabellenmittelfeld (rot) und einen Absteiger (grün) aus der Saison 2019 der Top-5-Ligen Europas.

Zur inhaltlichen Interpretation der Hauptkomponenten werden zunächst die jeweiligen Ladungen betrachtet, aus denen sich auch die gewählten Bezeichnungen der Komponenten ergeben. Tabellen mit einer Übersicht über die stärksten Ladungen der ersten zehn Hauptkomponenten sowie mögliche Bezeichnungen finden sich im Anhang (vgl. Abschnitt 7.5).

Die erste Hauptkomponente wird nahezu ausschließlich durch Variablen des Pass- und Ballbesitzspiels bestimmt. Kennzahlen wie die Anzahl gespielter Pässe, die gesamte Passdistanz, Ballkontakte, Ballbesitz sowie Ballführungen weisen die größten negativen Ladungen auf. Diese Variablen erfassen Aspekte der Spielgestaltung und lassen sich daher als Ausdruck von Ballbesitz und Spielkontrolle interpretieren. Vor diesem Hintergrund wird die Hauptkomponente im Folgenden als *Spielkontrolle* bezeichnet. Da die dominierenden Ladungen negativ sind, entsprechen niedrige Werte




Abbildung 3: Darstellung der ersten drei Hauptkomponenten für ausgewählte Teams der Saison 2019 der Top-5-Ligen Europas. Gezeigt sind jeweils der Meister (blau), ein Team aus dem Tabellenmittelfeld (rot) sowie ein Absteiger (grün). Die Projektionen der Teams im Raum der Hauptkomponenten verdeutlichen Unterschiede in ihren Spielstilen.

auf dieser Komponente einer hohen Ausprägung der zugehörigen Merkmale. In Abbildung 3 zeigt sich, dass diese Komponente die Teams der Kategorie Meister von den übrigen Mannschaften trennt.

Die zweite Hauptkomponente wird vor allem durch defensive Aktionen wie Tacklings, gewonnene Zweikämpfe sowie Tacklings in verschiedenen Spielfeldzonen geprägt. Diese Variablen erfassen primär die Intensität und Häufigkeit defensiver Eingriffe und können daher als Ausdruck der Defensivarbeit interpretiert werden. Entsprechend wird diese Komponente als *Defensivintensität* bezeichnet. Im Gegensatz zur *Spielkontrolle* zeigt sich hier eine größere Streuung ohne Trennung nach Tabellenposition.

Die dritte Hauptkomponente weist eine gegenläufige Struktur auf. Während offensive Kennzahlen wie Schüsse, Schüsse auf das Tor, erwartete Tore und erwartete Torvorlagen negative Ladungen aufweisen, sind defensive Variablen wie Tacklings und gewonnene Tacklings positiv geladen. Diese Gegenläufigkeit kann als Verhältnis zwischen offensiver Chancenproduktion und defensiver Aktivität interpretiert werden. Die Komponente wird daher im Folgenden als *Spielbalance* bezeichnet. Niedrige Werte stehen für eine offensivere Orientierung, während hohe Werte mit einer erhöhten Defensivaktivität verbunden sind. In Abbildung 3 zeigt sich, dass Absteiger

auf dieser Komponente überwiegend hohe Werte aufweisen. Auffällig ist zudem, dass Meisterteams häufig Werte nahe null erreichen, was auf ein vergleichsweise ausgewogenes Verhältnis zwischen offensiver Produktion und defensiver Aktivität hindeutet. Teams aus dem Tabellenmittelfeld weisen dagegen teilweise sehr niedrige Werte auf, was als hohe offensive Aktivität ohne die *Spielkontrolle* der Spitzenmannschaften interpretiert werden kann.

Wie in Gleichung 1 beschrieben, ergeben sich die Werte der Hauptkomponenten als lineare Kombinationen vieler Variablen. Dies lässt sich exemplarisch anhand

| Bayern München      |        | ACF Fiorentina              |        |
|---------------------|--------|-----------------------------|--------|
| <i>Spielbalance</i> | -1.08  | <i>Spielbalance</i>         | -1.03  |
| xA                  | -0.451 | Tacklings + Interceptions   | -0.115 |
| npxG                | -0.449 | gewonnene Tacklings         | -0.098 |
| xG                  | -0.432 | Tacklings (gewonnen)        | -0.098 |
| xAG                 | -0.412 | Schüsse                     | -0.096 |
| Strafraumkontakte   | -0.332 | Key Pässe                   | -0.094 |
| Schüsse (auf Tor)   | -0.307 | Tacklings gesamt            | -0.082 |
| Schüsse             | -0.271 | Tacklings Defensivdrittel   | -0.076 |
| Key Pässe           | -0.266 | Strafraumkontakte           | -0.070 |
| Mittlere Pässe      | 0.244  | Passquote (mittel)          | 0.051  |
| Pässe gesamt        | 0.210  | Chancen nach Schussaktionen | -0.050 |

Tabelle 1: Wichtigste Variablenbeiträge zur Hauptkomponente *Spielbalance* für Bayern München und die ACF Fiorentina

der *Spielbalance* verdeutlichen. Tabelle 1 zeigt die wichtigsten Variablenbeiträge für Bayern München und die ACF Fiorentina. Beide Teams weisen sehr ähnliche negative Werte für diese Hauptkomponente auf.

Die negativen Komponentenwerte des FC Bayern Münchens ergeben sich aus hohen Beiträgen offensiver Variablen wie erwartete Tore (xG), nicht-elfmeterbedingte erwartete Tore (npxG), erwartete Assists (xA) sowie Schüsse und Key-Pässe. Diese Variablen tragen maßgeblich zur negativen Ausprägung der Komponente bei. Gleichzeitig wirken jedoch positive Beiträge aus passbezogenen Variablen wie mittlere und gesamte Pässe dieser negativen Ausprägung entgegen, sodass sich insgesamt ein weniger stark negativer Komponentenwert ergibt.

Im Vergleich dazu zeigt sich bei der ACF Fiorentina eine defensiv geprägte Struktur der Beiträge. Hier dominieren Variablen wie Tacklings, Interceptions und Defensivaktionen im eigenen Drittel, die ebenfalls negativ zur Komponente beitragen. Offensivmetriken spielen hingegen eine geringere Rolle.

Obwohl beide Teams ähnliche Werte in der *Spielbalance*-Komponente aufweisen, resultieren diese aus unterschiedlichen Variablenkombinationen. Dies verdeutlicht, dass die Hauptkomponenten nicht eindimensional zu interpretieren sind, sondern verschiedene Spielstilmuster zu einer einzigen Kennzahl bündeln. Insbesondere bei komplexeren Komponenten mit gegenläufigen Ladungsstrukturen ist die inhaltliche Interpretation und Vergleichbarkeit eingeschränkt.

Dennoch ist die Verwendung der PCA sinnvoll: Durch die Reduktion einer Vielzahl korrelierter Variablen auf wenige zentrale Dimensionen wird die Komplexität des Datensatzes reduziert. Die Hauptkomponenten ermöglichen somit eine kompakte Beschreibung zentraler Spielcharakteristika. Die Interpretation erfolgt dabei anhand der Variablen mit den größten Ladungen, welche die jeweilige Dimension maßgeblich prägen. Auch wenn diese Interpretation nicht immer eindeutig ist, liefert sie dennoch inhaltliche Erkenntnisse.

Ein Problem bei der Anwendung von Dimensionsreduktionsverfahren wie der Hauptkomponentenanalyse im Kontext von Vorhersagemodellen ist, dass es zu so genanntem *Data Leakage* kommen kann, wenn diese auf dem gesamten Datensatz geschätzt werden, da dadurch Informationen aus dem Testzeitraum in die Modellierung einfließen (Kaufman et al., 2012). Um bei der Vorhersage von Toren die Verwendung solcher Informationen zu vermeiden, wird die Hauptkomponentenanalyse in dieser Arbeit ausschließlich auf Basis der im Folgenden beschriebenen Trainingsdaten geschätzt. Die daraus resultierenden Ladungen werden anschließend auf alle Beobachtungen angewendet. Zusätzlich werden die resultierenden Hauptkomponentenwerte getrennt für die jeweils letzten drei Heim- bzw. Auswärtsspiele gemittelt und zur Vorhersage des aktuellen Spiels verwendet. Zur Vorhersage eines Spiels werden somit ausschließlich Informationen aus vorangegangenen Spielen herangezogen. Dieses Vorgehen verhindert nicht nur Data Leakage, sondern stellt gleichzeitig sicher, dass die Hauptkomponenten die aktuelle Leistungsform einer Mannschaft abbilden.

Die Relevanz der Unterscheidung zwischen Heim- und Auswärtsspielen wird in Abbildung 4 deutlich. Es zeigt sich, dass die Positionen der Teams im Raum der Hauptkomponenten systematisch zwischen Heim- und Auswärtsspielen variieren, wobei die Ausprägungen bei Auswärtsspielen im Durchschnitt schwächer sind.

Zusätzlich wurden, analog zu den Spieler- und Marktwertvariablen, Differenzvariablen zwischen den beiden Teams gebildet. Dabei wurden sowohl direkte Differenzen derselben Hauptkomponenten als auch gezielte Kreuz-Differenzen zwischen unterschiedlichen Hauptkomponenten berücksichtigt. Die Hauptkomponentenpaare der Kreuz-Differenzen wurden auf Basis von inhaltlichen Interpretationen der




Abbildung 4: Darstellung der ersten Hauptkomponenten für ausgewählte Teams. Blaue Punkte entsprechen Heimspielen, rote Punkte Auswärtsspielen. Linien verbinden jeweils die Werte der Heim- und Auswärtsspiele eines Teams.

Hauptkomponenten ausgewählt und sind in Tabelle 2 dargestellt.

| Variable       | Interpretation                                    |
|----------------|---------------------------------------------------|
| pc1_vs_opp_pc2 | Spielkontrolle vs. gegnerische Defensivintensität |
| pc1_vs_opp_pc6 | Spielkontrolle vs. gegnerische Torwartstärke      |
| pc1_vs_opp_pc8 | Spielkontrolle vs. gegnerische Absicherung        |
| pc3_vs_opp_pc2 | Spielbalance vs. gegnerische Defensivintensität   |
| pc4_vs_opp_pc6 | Effizienz vs. gegnerische Torwartstärke           |

Tabelle 2: Gezielte Kreuz-Differenzen zwischen Hauptkomponenten

Während einfache Differenzen identischer Hauptkomponenten relative Unterschiede innerhalb einzelner Spielstildimensionen erfassen, berücksichtigen diese Kreuz-Differenzen gezielt das Aufeinandertreffen unterschiedlicher Eigenschaften beider Mannschaften.

## 2.3 Fehlende Schlüsselspieler

Ein Einflussfaktor auf den Ausgang eines Fußballspiels ist die Verfügbarkeit von Schlüsselspielern. In dem bestehenden Datensatz wird die Qualität eines Kaders jedoch nur aggregiert betrachtet, etwa über durchschnittliche Ratings oder Ge-



samtmarktwerte. Solche aggregierten Maße berücksichtigen nicht, welche Spieler tatsächlich zur Verfügung stehen und somit bleibt unberücksichtigt, dass der Ausfall einzelner Schlüsselspieler je nach Position unterschiedliche Auswirkungen haben kann.

Ziel der folgenden Variablenkonstruktion war es, die personelle Schwächung einer Mannschaft vor einem Spiel abzubilden. Anstatt nur die durchschnittliche Kaderqualität zu betrachten, wurde erfasst, wie viele der Schlüsselspieler einer Mannschaft in einzelnen Positionsgruppen fehlen. Für diesen Ansatz wurden für jede Mannschaft und jede Saison positionsspezifische Wichtigkeitswerte für einzelne Spieler konstruiert. Analog zur Konstruktion der Hauptkomponentenvariablen wurde auch bei der Konstruktion dieser Variablen darauf geachtet, Data Leakage zu vermeiden, indem ausschließlich Informationen verwendet wurden, die zum jeweiligen Prognosezeitpunkt verfügbar waren.

Für die Zuordnung der Spieler zu Positionsgruppen wurden Daten der gesamten Saison herangezogen. Dazu wurden die Positionen, auf denen die Spieler eingesetzt wurden zu den vier Kategorien *Torwart* (GK), *Abwehr* (DEF), *Mittelfeld* (MID) und *Angriff* (ATT) zusammengefasst. Jeder Spieler wurde dabei genau einer Positionsgruppe zugeordnet, und zwar derjenigen, auf der er im Datensatz (FBref, 2026) am häufigsten eingesetzt wurde. Dabei handelt es sich nicht um Data Leakage, denn die grundsätzliche Position eines Spielers ist unabhängig vom Spielverlauf im Vorfeld bekannt. Somit handelt es sich hierbei lediglich um eine Automatisierung der Positionszuordnung.

Zur Approximation der Spielerwichtigkeit wurde ein bayesianisch inspirierter Ansatz gewählt, bei dem die Wichtigkeit eines Spielers zunächst durch einen sogenannten *Prior* beschrieben wird, der auf Informationen aus der Vorsaison, beziehungsweise im Fall fehlender Historie, auf positions- und teamspezifischen Startwerten basiert. Dieser Prior wird anschließend mit einer aktuellen Formkomponente der laufenden Saison verrechnet, um ein gewichtetes Maß zu erhalten, das sowohl historische als auch kurzfristige Informationen berücksichtigt.

Für Spieler mit Vorsaisoninformationen ergibt sich der Prior aus:

$$b_i^{\text{base}} = 0.7 \bar{s}_i^{\text{prev}} + 0.3 \left( \frac{m}{90} \right)_i^{\text{prev}},$$

wobei  $\bar{s}_i^{\text{prev}}$  die durchschnittliche Startelfwahrscheinlichkeit und  $\left( \frac{m}{90} \right)_i^{\text{prev}}$  den durchschnittlichen Anteil der gespielten Minuten pro Spiel des Spielers  $i$  in der Vorsaison bezeichnet.

Für die Berechnung der Wichtigkeit in der aktuellen Saison wurde zunächst ein Nutzungswert definiert:

$$u_{i,t} = 0.7 s_{i,t} + 0.3 \frac{m_{i,t}}{90},$$

wobei  $u_{i,t}$  den Nutzungswert von Spieler  $i$  im Spiel  $t$ ,  $s_{i,t} \in \{0, 1\}$  einen Indikator für einen Starteinsatz und  $m_{i,t}$  die Anzahl der gespielten Minuten bezeichnet.

Starteinsätze werden dabei bewusst stärker gewichtet als die gespielten Minuten, da sie die geplante Rolle eines Spielers innerhalb der Mannschaft besser widerspiegeln. Die Einsatzzeit kann durch situative Faktoren, wie z.B. durch verletzungsbedingte Auswechslungen, verzerrt sein. Würden die gespielten Minuten gleich stark gewichtet, könnten frühzeitige verletzungsbedingte Auswechslungen von wichtigen Spielern zu einer systematischen Unterschätzung der Nutzungswerte dieser Spieler führen. Durch die stärkere Gewichtung des Starteinsatzes wird diesem Verzerrungseffekt entgegengewirkt.

Für Spieler ohne eigene Vorsaisoninformationen, etwa Neuzugänge, wurde ein initialer Median-Startwert  $b_i^{\text{start}}$  verwendet, damit die Wichtigkeit dieser Spieler nicht durch das Fehlen von Informationen verzerrt wird. Dazu wird der Median aus positions- und teamspezifischen Einsatzzeiten gebildet. Dieser Median-Startwert soll dann mithilfe der Nutzungswerte  $\bar{u}_{i,1:n_i}$  aus den ersten 5 Spielen schrittweise angepasst werden, um so die Informationen der Vorsaison zu simulieren und schließlich für den Rest der Saison als Prior zu dienen.

Der Prior ergibt sich dann insgesamt aus:

$$b_i^{\text{prior}} = \begin{cases} b_i^{\text{base}}, & \text{falls Vorsaisoninformationen vorliegen,} \\ b_i^{\text{start}}, & \text{falls } n_i = 0, \\ \frac{b_i^{\text{start}} + n_i \bar{u}_{i,1:n_i}}{1 + n_i}, & \text{falls } 1 \leq n_i < 5, \\ \frac{b_i^{\text{start}} + 5 \bar{u}_{i,1:5}}{6}, & \text{falls } n_i \geq 5. \end{cases}$$

wobei  $n_i$  die Anzahl der bisher beobachteten Einsätze des Spielers  $i$  in der laufenden Saison bezeichnet und  $\bar{u}_{i,1:n_i}$  den Durchschnitt der Nutzungswerte aus den ersten  $n_i$  Einsätzen darstellt.

Auf diese Weise wird sichergestellt, dass auch Spieler ohne historische Informationen, insbesondere Neuzugänge, realistisch bewertet werden. Spieler, die sich früh in der Saison als Schlüsselspieler etablieren, erhalten dadurch schnell einen hohen Prior-Wert, während Spieler mit geringer Einsatzzeit niedrig bewertet werden. Der

Prior bildet somit eine robuste Schätzung der grundsätzlichen Bedeutung eines Spielers, die sowohl etablierte Leistungsträger als auch neu integrierte Spieler angemessen berücksichtigt. Dies ermöglicht es, dass wichtige Neuzugänge, die im weiteren Saisonverlauf ausfallen, korrekt als fehlende Schlüsselspieler identifiziert werden.

Der vorher berechnete Nutzungswert diene anschließend als Grundlage zur Konstruktion einer kurzfristigen Formkomponente. Dazu wurde der Durchschnitt der Nutzungswerte aus den letzten fünf Einsätzen eines Spielers berechnet:

$$f_i = \frac{1}{K_i} \sum_{k=1}^{K_i} u_{i,t-k},$$

wobei  $K_i = \min(5, n_i)$  die Anzahl der berücksichtigten Spiele darstellt, sodass maximal die letzten fünf Einsätze in die Formkomponente eingehen. Dabei werden ausschließlich Spiele berücksichtigt, in denen der Spieler im Spieltagskader stand. Dies hat zur Folge, dass sich der Formwert eines Spielers während Phasen ohne Kaderzugehörigkeit, beispielsweise aufgrund von Verletzungen oder Sperren, nicht weiter verändert. Die Formkomponente bleibt in diesen Fällen konstant, bis der Spieler wieder Einsätze verzeichnet. Dadurch verlieren Langzeitverletzte nicht im Laufe der Saison ihren Status als Schlüsselspieler. Zusätzlich rechtfertigt diese Konstruktion zugleich eine stärkere Gewichtung von Startelfeinsätzen im Nutzungswert. Denn ohne diese Gewichtung könnten frühzeitige, verletzungsbedingte Auswechslungen zu einem dauerhaft zu niedrigen Formwert führen, da der durch die Auswechslung reduzierte Nutzungswert in die Durchschnittsbildung eingeht und anschließend bis zur Rückkehr in den Spieltagskader konstant gehalten wird.

Der finale Wichtigkeitswert eines Spielers ergibt sich dann als gewichtete Kombination aus Prior und aktueller Form:

$$I_i = 0.3 b_i^{\text{prior}} + 0.7 f_i.$$

Auf Basis dieses Wichtigkeitswertes wurden anschließend für jede Mannschaft, Saison und Positionsgruppe die Schlüsselspieler ausgewählt. Dabei wurden pro Mannschaft genau ein Torwart, vier Verteidiger, drei Mittelfeldspieler und drei Angreifer als positionsspezifische Schlüsselspieler definiert. Diese Aufteilung stellt eine ausgewogene Abbildung der Mannschaftsstruktur dar und entspricht näherungsweise der Rollenverteilung der beiden am häufigsten beobachteten Formationen 4-2-3-1 und 4-3-3. Anschließend wurde für jedes Spiel gezählt, wie viele Schlüsselspieler in den jeweiligen Kader- oder Startelfpositionen fehlten. Daraus wurden Variablen

zur Erfassung der fehlenden Schlüsselspieler pro Mannschaft und Positionsgruppe konstruiert.

## 2.4 Finaler Modell-Datensatz

Der finale Modell-Datensatz umfasst insgesamt 6.956 Beobachtungen und 143 Variablen, bestehend aus den beschriebenen Variablenkonstruktionen und einigen Spielkontext- und Formvariablen. Die Daten liegen im *Long-Format* vor, sodass jedes Spiel durch zwei Beobachtungen (Heim- und Auswärtsteam) repräsentiert wird, was insgesamt 3.478 Spielen entspricht. Dieses Format ermöglicht es, die Variablen beider Teams direkt miteinander in Beziehung zu setzen, sodass die Schätzung der erzielten Tore den jeweiligen Spiel- und Gegnerkontext berücksichtigt.

Für die Modellschätzung wird ein zeitbasierter Trainings- und Testsplit verwendet. Der Trainingsdatensatz umfasst 5.058 Beobachtungen aus den Saisons 2017/18 und 2018/19, während der Testdatensatz 1.898 Beobachtungen aus der Saison 2019/20 enthält. Durch diese zeitliche Trennung wird sichergestellt, dass das Modell ausschließlich auf Basis vergangener Informationen geschätzt und auf zeitlich nachgelagerten Daten evaluiert wird. Gleichzeitig wird verhindert, dass Informationen aus dem Testzeitraum in den Trainingsprozess einfließen, was zu einer systematischen Überschätzung der Modellgüte führen könnte (Kaufman et al., 2012).

### 3 Methodik

Die Zielvariable  $Y_{ij}$  beschreibt die von Team  $i$  im Spiel  $j$  erzielte Toranzahl. Wie bereits in Abschnitt 2.1 dargestellt, handelt es sich bei den Beobachtungen um Zähldaten, weshalb ein Poisson-Modell mit Log-Link verwendet wird:

$$Y_{ij} \sim \text{Poisson}(\mu_{ij}), \quad \log(\mu_{ij}) = \eta_{ij}.$$

Der lineare Prädiktor  $\eta_{ij}$  setzt sich aus einem Intercept, den fixen Effekten der 143 Kovariaten sowie einem team- und spielortbezogenen Zufallseffekt zusammen.

$$\eta_{ij} = \beta_0 + \mathbf{x}_{ij}^\top \boldsymbol{\beta} + \gamma_{i,l}, \quad l \in \{H, A\}.$$

Der Zufallseffekt  $\gamma_{i,l}$  modelliert die Interaktion aus Team  $i$  und Spielort  $l$ , sodass jedes Team separate Effekte für Heim- und Auswärtsspiele erhält. Die Gesamtheit aller Zufallseffekte wird für die  $I$  im Datensatz enthaltenen Teams im Vektor

$$\boldsymbol{\gamma} = (\gamma_{1,H}, \gamma_{1,A}, \dots, \gamma_{I,H}, \gamma_{I,A})^\top$$

zusammengefasst. Formal wird angenommen:

$$\boldsymbol{\gamma} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}),$$

wobei  $\mathbf{Q}$  die Kovarianzmatrix der Zufallseffekte bezeichnet.

Durch die Einführung dieser zufälligen Effekte befindet sich das Modell im Rahmen eines generalisierten linearen gemischten Modells (GLMM), welches feste und zufällige Effekte kombiniert (Fahrmeir et al., 2009). Die zufälligen Effekte können dabei als team- und spielortspezifische Abweichungen vom globalen Mittelwert interpretiert werden. Im vorliegenden Fall handelt es sich um *Random Intercepts*, die für jede Kombination aus Team und Spielort modelliert werden. Die Annahme einer Normalverteilung der Zufallseffekte stellt dabei den Standard in gemischten Modellen dar und ermöglicht eine Modellierung unbeobachteter Heterogenität zwischen den Teams (Fahrmeir et al., 2009).

Aufgrund der hohen Dimensionalität des Datensatzes und der teils ausgeprägten Korrelation zwischen einzelnen Kovariatengruppen wird zur Schätzung des finalen Modells modellbasiertes komponentenweises Gradienten-Boosting verwendet. Eine Übersicht der paarweisen Korrelationen der numerischen Variablen des Datensatzes

ist in der Korrelationsmatrix im Anhang dargestellt (vgl. Abschnitt 7.7).

### 3.1 Modellbasiertes komponentenweises Gradienten-Boosting

Die Grundidee des modellbasierten komponentenweisen Gradienten-Boostings besteht darin, die Vorhersagekraft sogenannter schwacher Basislerner durch iterative Kombination zu verstärken (Friedman, 2001; Bühlmann and Hothorn, 2007). Das Verfahren basiert auf einem Gradientenabstieg im Funktionenraum, bei dem in jedem Iterationsschritt  $m$  der negative Gradientenvektor der Verlustfunktion  $\rho(\mathbf{y}, \boldsymbol{\eta})$  berechnet wird.

Im vorliegenden Anwendungsfall wird zur Darstellung des Gradienten-Boostings zunächst die negative Log-Likelihood der Poisson-Verteilung ohne Berücksichtigung zufälliger Effekte als Verlustfunktion verwendet. Im Abschnitt 3.2 wird die Verlustfunktion um die zufälligen Effekte erweitert. Für eine einzelne Beobachtung ergibt sich

$$\rho(y_{ij}, \eta_{ij}) = -\log \Pr(Y_{ij} = y_{ij} \mid \eta_{ij}) = \exp(\eta_{ij}) - y_{ij}\eta_{ij} + \log(y_{ij}!),$$

mit  $\mu_{ij} = \exp(\eta_{ij})$ .

Die über alle Beobachtungen zu minimierende empirische Verlustfunktion lautet damit

$$R(\boldsymbol{\eta}) = \sum_{(i,j) \in \mathcal{J}} \rho(y_{ij}, \eta_{ij}),$$

wobei  $\mathcal{J}$  die Menge aller Beobachtungsindizes bezeichnet.

Die Ableitung der Verlustfunktion nach dem linearen Prädiktor ergibt

$$\frac{\partial \rho(y_{ij}, \eta_{ij})}{\partial \eta_{ij}} = \exp(\eta_{ij}) - y_{ij} = \mu_{ij} - y_{ij}.$$

Der negative Gradient, der im Boosting-Verfahren als Pseudo-Residuum verwendet wird, entspricht somit

$$u_{ij} = y_{ij} - \mu_{ij}.$$

In jedem Iterationsschritt wird derjenige Basislerner an die Pseudo-Residuen angepasst, der die größte Reduktion der Verlustfunktion erzielt, wodurch Modellschätzung und automatische Variablenselektion miteinander kombiniert werden (Friedman, 2001). Im vorliegenden Fall entsprechen die Basislerner einfachen linearen Regressionsmodellen. Grundsätzlich können im Rahmen des Gradienten-Boostings jedoch auch andere Basislerner verwendet werden, etwa zur Abbildung nichtlinea-

rer Effekte durch Splines. Kleine Schrittweiten zwischen 0 und 1, typischerweise  $\nu = 0.1$ , sowie ein frühzeitiges Stoppen wirken als Regularisierung und wirken einer Überanpassung des Modells an die Trainingsdaten entgegen (Bühlmann and Yu, 2003). Zudem gilt Gradienten-Boosting als vergleichsweise robust gegenüber Multikollinearität, was unter anderem auf die schrittweise und geschrumpfte Anpassung der Effekte zurückgeführt werden kann (Mayr et al., 2014). Da die Anzahl der Iterationen die Ergebnisse stark beeinflusst, gilt die Wahl der optimalen Stoppiteration  $m^*$  als wichtigster Optimierungsparameter des Gradienten-Boostings (Mayr et al., 2012).

Der beschriebene Ablauf des komponentenweisen Gradienten-Boostings ist in Algorithmus 1 zusammengefasst. Die bisherige Darstellung bezieht sich auf Gradienten-Boosting ohne Berücksichtigung von Zufallseffekten. Da im vorliegenden Anwendungsfall wiederholte Beobachtungen auf Teamebene vorliegen, ist die Annahme unabhängiger Beobachtungen jedoch verletzt. Komponentenweises Gradienten-Boosting kann Zufallseffekte grundsätzlich modellieren, etwa über entsprechende Random-Effects-Basislerner, wie sie beispielsweise im R-Paket `mboost` implementiert sind. Dabei werden fixe und zufällige Effekte innerhalb desselben Selektionsmechanismus geschätzt, sodass sie miteinander konkurrieren. Dies kann insbesondere bei clusterkonstanten Kovariaten zu verzerrten Parameterschätzungen führen (Griesbach et al., 2021). Der vorliegende Datensatz enthält zwar keine Kovariaten, die für jedes Team konstant sind, dennoch soll der Vorteil der getrennten Selektion fixer Effekte sowie der separaten Schätzung der Kovarianzstruktur der Zufallseffekte genutzt werden.

Aus diesem Grund wird im Folgenden das `mermboost`-Verfahren verwendet, das eine getrennte Schätzung von fixen und zufälligen Effekten innerhalb des Boosting-Rahmens ermöglicht (Knieper et al., 2025).

---

**Algorithm 1** Komponentenweises Gradienten-Boosting

---

- 1: Initialisiere  $\hat{\boldsymbol{\eta}}^{[0]}$
- 2: Wähle Basislerner  $b_1(\cdot), \dots, b_p(\cdot)$
- 3: Wähle Schrittweite  $\nu$  und maximale Iterationszahl  $m_{\text{stop}}$
- 4: **for**  $m = 1, \dots, m_{\text{stop}}$  **do**
- 5:     Berechne die Pseudo-Residuen

$$u_{ij}^{[m]} = y_{ij} - \mu_{ij}^{[m-1]} \quad \text{für alle } (i, j) \in \mathcal{J}$$

- 6:     Schätze alle Basislerner  $\hat{b}_r^{[m]}(x_{ijr})$  für  $r = 1, \dots, p$  separat anhand der Pseudo-Residuen  $u_{ij}^{[m]}$
- 7:     Wähle den besten Basislerner

$$r^* = \arg \min_r \sum_{(i,j) \in \mathcal{J}} \left( u_{ij}^{[m]} - \hat{b}_r^{[m]}(x_{ijr}) \right)^2$$

- 8:     Aktualisiere den linearen Prädiktor

$$\hat{\eta}_{ij}^{[m]} = \hat{\eta}_{ij}^{[m-1]} + \nu \hat{b}_{r^*}^{[m]}(x_{ijr^*}) \quad \text{für alle } (i, j) \in \mathcal{J}$$

- 9: **end for**
  - 10: Bestimme die optimale Iteration  $m^*$
  - 11: Gib  $\hat{\boldsymbol{\eta}}^{[m^*]}$  aus
- 

### 3.2 Modellschätzung mittels Mermboost

Das von Knieper et al. (2025) vorgeschlagene `mermboost`-Verfahren ermöglicht es, die im komponentenweisen Gradienten-Boosting auftretende Konkurrenz zwischen fixen und zufälligen Effekten zu vermeiden.

Zusätzlich zur Initialisierung des linearen Prädiktors in Schritt 1 des Algorithmus 1 wird ein initiales gemischtes Modell ohne Kovariaten, jedoch unter Berücksichtigung der gewählten Verteilungsannahme, geschätzt. Dieses liefert Startwerte für den linearen Prädiktor  $\hat{\boldsymbol{\eta}}^{[0]}$  sowie für die Struktur der Zufallseffekte, die durch den Vektor der Zufallseffekte  $\tilde{\boldsymbol{\gamma}}^{[0]}$  und die zugehörige Kovarianzmatrix  $\hat{\mathbf{Q}}^{[0]}$  beschrieben wird.

Nach der Aktualisierung der fixen Effekte wird die zuvor für die festen Effekte verwendete Verlustfunktion um die Struktur der Zufallseffekte erweitert, indem die zufälligen Effekte sowie deren Kovarianzmatrix über die penalisierte Likelihood separat neu geschätzt werden. Dies erfolgt durch Einsetzen des aktuellen festen Anteils  $\hat{\boldsymbol{\eta}}_{\text{fix}}^{[m]}$  in die penalisierte Likelihood  $\ell_{\text{pen}}$ , die sich aus der Modell-Likelihood sowie einem Strafterm für die Zufallseffekte zusammensetzt (vgl. Anhang 7.8), und deren



anschließende Maximierung bezüglich der Parameter der Zufallseffekte:

$$\hat{\phi}^{[m]} = (\hat{\gamma}^{[m]}, \hat{\mathbf{Q}}^{[m]}) = \arg \max_{\gamma, \mathbf{Q}} \ell_{\text{pen}}(\boldsymbol{\theta}^{[m]}, \phi; \mathbf{Y}).$$

Dabei bezeichnet  $\phi = (\gamma, \mathbf{Q})$  den Parametervektor der Struktur der Zufallseffekte, während  $\boldsymbol{\theta} = (\beta_0, \boldsymbol{\beta}^\top)^\top$  den Parametervektor der fixen Effekte darstellt. Die Indizierung  $[m]$  kennzeichnet die jeweilige Iteration des Verfahrens.

Die in Iteration  $m$  erhaltenen Schätzungen  $\tilde{\gamma}^{[m]}$  und  $\hat{\mathbf{Q}}^{[m]}$  stellen zunächst unkorrigierte Zufallseffekte und die zugehörige geschätzte Kovarianzmatrix dar. Zur Vermeidung von Verzerrungen bei der Parameterschätzung, insbesondere im Zusammenhang mit cluster-konstanten Kovariaten, bei denen es zu einer Fehlzuordnung von Effekten zwischen fixen und zufälligen Komponenten kommen kann, werden die Zufallseffekte anschließend mithilfe einer Korrekturmatrix  $\mathbf{C}$  angepasst:

$$\hat{\gamma}^{[m]} = \mathbf{C} \tilde{\gamma}^{[m]}.$$

Für weitere Details zur Konstruktion der Korrekturmatrix  $\mathbf{C}$ , die Orthogonalität zwischen zufälligen Effekten und cluster-konstanten fixen Effekten herstellt, wird auf Griesbach et al. (2021) verwiesen. In der vorliegenden Datenanwendung liegen jedoch keine cluster-konstanten Kovariaten vor, sodass  $\mathbf{C}$  der Einheitsmatrix entspricht und damit  $\hat{\gamma}^{[m]} = \tilde{\gamma}^{[m]}$  gilt.

Anschließend wird der zufällige Anteil des linearen Prädiktors  $\hat{\boldsymbol{\eta}}_{\text{random}}^{[m]}$  aktualisiert, indem die bisherigen Zufallseffekte  $\hat{\gamma}^{[m-1]}$  durch die korrigierten Schätzungen  $\hat{\gamma}^{[m]}$  ersetzt werden.

Der lineare Prädiktor ergibt sich schließlich als Summe aus fixem und zufälligem Anteil:

$$\hat{\boldsymbol{\eta}}^{[m]} = \hat{\boldsymbol{\eta}}_{\text{fix}}^{[m]} + \hat{\boldsymbol{\eta}}_{\text{random}}^{[m]}.$$

Das **mermboost**-Verfahren erweitert somit den in Algorithmus 1 dargestellten Ablauf um eine separate Schätzung der Zufallseffekte sowie deren Kovarianzmatrix  $\mathbf{Q}$ . Durch die Trennung der komponentenweisen Schätzung der fixen Effekte und der iterativen Aktualisierung der Zufallseffekte wird die Konkurrenz zwischen beiden Komponenten vermieden und eine Anpassung der cluster-spezifischen Effekte in jeder Boosting-Iteration sichergestellt. In Kombination mit der Korrektur der Zufallseffekte und der Schätzung von  $\mathbf{Q}$  stellt dieser Schritt die zentrale methodische Erweiterung des **mermboost**-Verfahrens dar und wird iterativ bis zum Erreichen der optimalen Stoppiteration  $m^*$  durchgeführt. Für weitere Details zum ursprünglich

von Knieper et al. (2025) vorgeschlagenen Verfahren wird auf die dortige Darstellung verwiesen.

### 3.3 Bestimmung der optimalen Stoppiteration

Kreuzvalidierung ist ein verbreitetes Resampling-Verfahren zur Schätzung des erwarteten Vorhersagefehlers eines Modells auf bislang unbeobachteten Daten. Im Fall der  $K$ -fachen Kreuzvalidierung wird der Datensatz in  $K$  annähernd gleich große Teilmengen zerlegt. Anschließend wird das Modell  $K$ -mal geschätzt, wobei jeweils  $K - 1$  Teilmengen zum Training und die verbleibende Teilmenge zur Validierung verwendet werden. Der Vorhersagefehler ergibt sich als Mittelwert der auf den jeweiligen Validierungsmengen berechneten Prognosefehler:

$$CV(\hat{f}) = \frac{1}{N} \sum_{i=1}^N L\left(y_i, \hat{f}^{-\kappa(i)}(x_i)\right).$$

Dabei bezeichnet  $N$  die Anzahl der Beobachtungen,  $L(\cdot, \cdot)$  die gewählte Verlustfunktion,  $\kappa(i) \in \{1, \dots, K\}$  die Zuordnung der  $i$ -ten Beobachtung zu einer der  $K$  Teilmengen und  $\hat{f}^{-\kappa(i)}(x_i)$  die Vorhersage für  $x_i$ , die aus einem Modell stammt, das ohne die Teilmenge geschätzt wurde, der Beobachtung  $i$  angehört (Hastie et al., 2009).

Für korrelierte beziehungsweise zeitlich strukturierte Daten hängt die Eignung von Kreuzvalidierung entscheidend davon ab, ob die Aufteilung in Trainings- und Testdaten die spätere Vorhersagesituation hinsichtlich ihrer Abhängigkeitsstruktur angemessen widerspiegelt. Ist dies nicht der Fall, kann Standard-Kreuzvalidierung zu verzerrten Fehlerschätzungen führen, sodass ein korrigiertes Kreuzvalidierungsverfahren erforderlich wäre (Rabinowicz and Rosset, 2022). Roberts et al. (2017) weisen darauf hin, dass zufällige (nicht korrigierte) Kreuzvalidierung bei zeitlich oder anderweitig strukturierten Daten zu systematisch zu optimistischen Fehlerschätzungen führen kann, da Trainings- und Testdaten dann häufig nicht hinreichend unabhängig sind. Vor diesem Hintergrund wird das von Thomas et al. (2017) vorgeschlagene *Probing* verwendet, welches die optimale Stoppiteration innerhalb eines einzelnen Boosting-Durchlaufs bestimmt und keine wiederholten zufälligen Resampling-Schritte erfordert.

Die Grundidee des Probing-Ansatzes besteht darin, den ursprünglichen Datensatz um künstlich erzeugte, nicht informative Shadow-Variablen zu erweitern. Hierzu wird für jede ursprüngliche Kovariate  $x_j$ ,  $j = 1, \dots, p$ , eine zufällig permutierte Va-

riable  $\tilde{x}_j$  erzeugt. Durch diese Permutation bleibt die Randverteilung der jeweiligen Kovariate erhalten, während ihr systematischer Zusammenhang zur Zielvariable aufgehoben wird. Dadurch fungieren die Shadow-Variablen als Referenzvariablen ohne inhaltliche Vorhersagekraft.

Bezeichnet

$$\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_p)$$

den ursprünglichen Kovariatensatz, so ergibt sich der erweiterte Datensatz zu

$$\mathbf{X}^{\text{aug}} = (\mathbf{x}_1, \dots, \mathbf{x}_p, \tilde{\mathbf{x}}_1, \dots, \tilde{\mathbf{x}}_p).$$

Auf diesem erweiterten Datensatz wird anschließend das komponentenweise Gradienten-Boosting durchgeführt. Da in jeder Iteration genau derjenige Basislerner ausgewählt wird, der die größte Reduktion der Verlustfunktion bewirkt, kann die erstmalige Selektion einer Shadow-Variable als Signal dafür interpretiert werden, dass unter den verbleibenden Kandidaten kein Prädiktor mehr vorhanden ist, der eine stärkere systematische Verbesserung liefert als eine künstlich erzeugte Variable.

Sei  $j_m^*$  der in Iteration  $m$  ausgewählte Basislerner. Dann ist die Probing-Stoppiteration definiert als

$$m_{\text{probe}} = \min \{m \geq 1 : j_m^* \in \{p+1, \dots, 2p\}\},$$

also als die erste Iteration, in der ein Basislerner gewählt wird, der auf einer Shadow-Variable basiert. Die durch Probing bestimmte optimale Stopppiteration ergibt sich damit zu

$$m_{\text{stop}}^{\text{probe}} = m_{\text{probe}} - 1.$$

Als informativ gelten folglich genau diejenigen Originalvariablen, deren Basislerner vor dem erstmaligen Eintritt einer Shadow-Variable selektiert wurden. Im Unterschied zu resampling-basierten Verfahren erfolgt die Bestimmung der Stopppiteration beim Probing innerhalb eines einzelnen Boosting-Laufs. Probing zielt damit nicht primär auf die Minimierung des Vorhersagefehlers, sondern auf eine sparsame und direkte Variablenselektion ab (Thomas et al., 2017). Gerade vor dem Hintergrund der hohen Dimensionalität des Datensatzes sowie der zeitlichen Struktur der Beobachtungen stellt Probing daher ein geeignetes Verfahren zur Bestimmung der Stopppiteration dar.

## 4 Ergebnisse

Für das finale Modell ergab sich nach Anwendung von Probing eine optimale Stop-iteration  $m^* = 62$ . Insgesamt standen 287 Basislerner inklusive Schattenvariablen zur Verfügung, von denen 14 einschließlich Intercept ausgewählt wurden. Abbildung 5 zeigt, wie sich die Koeffizienten der im finalen Modell ausgewählten Variablen über die 62 Boosting-Iterationen schrittweise aufbauen, während Abbildung 6 die finalen Koeffizientenwerte darstellt. Der Intercept mit  $\hat{\beta}_0 = 0.237$  beschreibt die erwartete Toranzahl eines Teams, wenn die übrigen Kovariaten keinen Beitrag zum linearen Prädiktor leisten. Auf der Originalskala entspricht dies  $\exp(0.237) \approx 1.27$  erwarteten Toren. Mit  $n = 16$  wurde der Intercept zudem am häufigsten zur Reduktion des Vorhersagefehlers ausgewählt.

Das logarithmierte Verhältnis aus der Gesamtwertung der Mittelfeldspieler und der gegnerischen Verteidiger wurde mit  $n = 8$  am zweithäufigsten ausgewählt und weist mit  $\hat{\beta} = 0.107$  den größten positiven Koeffizienten unter den inhaltlichen Kovariaten auf. Aufgrund des Log-Links im Poisson-Modell geht eine Erhöhung dieses standardisierten Prädiktors um eine Einheit ceteris paribus mit einer Multiplikation der erwarteten Toranzahl um den Faktor  $\exp(0.107) \approx 1.11$  einher, was einem Anstieg um rund 11 % entspricht. Da der Prädiktor standardisiert wurde, entspricht eine Einheit dabei nicht einem zusätzlichen Ratingpunkt, sondern einer Erhöhung des Rating-Verhältnisses um ca. 6.6 %.

Weitere erwähnenswerte Variablen sind das logarithmierte Verhältnis aus der Gesamtwertung der Offensivspieler und der gegnerischen Verteidigung ( $\hat{\beta} = 0.055, n = 4$ ), die Differenz der ersten Hauptkomponente *Spielkontrolle* der beiden Teams ( $\hat{\beta} = -0.049, n = 3$ ), das logarithmierte Verhältnis aus der Gesamtwertung der Offensivspieler und des gegnerischen Torwarts ( $\hat{\beta} = 0.049, n = 5$ ), der Heimvorteil ( $\hat{\beta} = 0.048, n = 6$ ), die Differenz aus den Hauptkomponenten *Spielkontrolle* und *Torwartstärke* ( $\hat{\beta} = -0.036, n = 5$ ), die Differenz der Form ( $\hat{\beta} = 0.036, n = 2$ ), sowie das logarithmierte Verhältnis des Marktwertes der Mittelfeldspieler beider Teams ( $\hat{\beta} = 0.03, n = 3$ ). Diese Variablen weisen alle ähnlich starke Koeffizientenwerte und Selektionshäufigkeiten auf.

Einzig die Differenz der ersten Hauptkomponente *Spielkontrolle*, die Differenz aus den Hauptkomponenten *Spielkontrolle* und *Torwartstärke* sowie die Variable zur Bestimmung fehlender Schlüsselspieler in der Offensive ( $\hat{\beta} = -0.004, n = 1$ ) gehen mit einem negativen Koeffizienten in das Modell ein. Dabei ist jedoch anzumerken, dass die Vorzeichen der Hauptkomponenten keine inhaltliche Bedeutung haben und in

diesem Fall, wie bereits in Abschnitt 2.2 erläutert, ein negativer Wert der Hauptkomponente *Spielkontrolle* auf eine starke Ausprägung dieser Eigenschaft hindeutet. Vor diesem Hintergrund ist davon auszugehen, dass die mit der *Spielkontrolle* zusammenhängenden Variablen trotz negativer Regressionskoeffizienten inhaltlich eher mit einem positiven Einfluss auf die Vorhersage der erzielten Tore verbunden sind. Damit verbleibt die Variable zur Bestimmung fehlender Schlüsselspieler in der Offensive als einziger klar negativ interpretierbarer Effekt im Modell.




Abbildung 5: Koeffizientenpfade der im Modell berücksichtigten Variablen im Verlauf der Boosting-Iterationen.

Neben den fixen Effekten berücksichtigt das finale Modell auch team- und spielort-bezogene Zufallseffekte. Die im *mermboost*-Verfahren separat geschätzte Kovarianzmatrix  $\mathbf{Q}$  der Zufallseffekte reduziert sich im vorliegenden Modell auf eine gemeinsame Varianzkomponente der Random Intercepts. Daraus ergibt sich eine geschätzte Standardabweichung von  $\hat{\sigma}_\gamma = 0.104$ , entsprechend einer Varianz von  $\hat{\sigma}_\gamma^2 = 0.0109$ . Die Zufallseffekte erfassen somit eine zusätzliche, durch die fixen Kovariaten nicht erklärte Heterogenität zwischen den Team-Spielort-Kombinationen.

Einzelne Zufallseffekte weichen deutlich von 0 ab. Für Heimspiele zeigt Paris Saint-Germain mit  $\hat{\gamma}_{i,H} = 0.180$  den stärksten positiven und Leicester City mit  $\hat{\gamma}_{i,H} = -0.114$  den stärksten negativen Zufallseffekt. Für Auswärtsspiele weist Hoffenheim mit  $\hat{\gamma}_{i,A} = 0.201$  den stärksten positiven, während Cagliari mit  $\hat{\gamma}_{i,A} = -0.098$  den stärksten negativen Zufallseffekt auf. Inhaltlich können diese Effekte als




Abbildung 6: Geschätzte Koeffizienten der ausgewählten Variablen sowie deren Auswahlhäufigkeit im Boosting-Verfahren.

team- und spielortspezifische Abweichungen interpretiert werden, die über die beobachteten Leistungs-, Marktwert-, Form- und Spielstilvariablen hinausgehen. Die jeweils stärksten positiven und negativen Zufallseffekte der Teams sind in den Abbildungen im Anhang dargestellt (vgl. Abschnitt 7.9).

Bei der Berechnung der Vorhersagen wurden die geschätzten Zufallseffekte für alle im Trainingsdatensatz beobachteten Team-Spielort-Kombinationen berücksichtigt. Für 1733 der 1898 Beobachtungen im Testdatensatz lag ein im Trainingsdatensatz geschätzter Zufallseffekt vor. Bei den verbleibenden 165 Beobachtungen (8.7 %) trat die entsprechende Team-Spielort-Kombination im Training nicht auf, sodass der Zufallseffekt auf 0 gesetzt wurde.

Zur Bewertung der Vorhersagegüte werden der Root Mean Squared Error (RMSE) und der Mean Absolute Error (MAE) verwendet.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Dabei bezeichnet  $y_i$  die tatsächlich erzielte Toranzahl der  $i$ -ten Beobachtung,  $\hat{y}_i$  die

durch das Modell vorhergesagte Toranzahl und  $n$  die Anzahl der Beobachtungen im Testdatensatz.

Beide Maße messen den Vorhersagefehler zwischen der vorhergesagten und der tatsächlich erzielten Toranzahl. Während der MAE als durchschnittliche absolute Vorhersagefehler gut interpretierbar ist, berücksichtigt der RMSE größere Fehler aufgrund der Quadrierung der Abweichungen stärker. Durch die gemeinsame Betrachtung beider Kennzahlen lässt sich somit sowohl die allgemeine Prognosegenauigkeit als auch die Sensitivität des Modells gegenüber größeren Vorhersagefehlern beurteilen.

| Modell              | RMSE         | MAE          |
|---------------------|--------------|--------------|
| Mittelwert-Baseline | 1,259        | 1,003        |
| Finales Modell      | <b>1,156</b> | <b>0,891</b> |

Tabelle 3: Metriken zur Vorhersagekraft bei erzielten Toren.

Tabelle 3 zeigt, dass das finale Modell die von einem Team in einem Spiel erzielte Toranzahl präziser vorhersagt als die naive Baseline, bestehend aus dem Mittelwert. Der RMSE sinkt von 1,259 auf 1,156, während der MAE von 1,003 auf 0,891 zurückgeht. Im Durchschnitt weichen die Vorhersagen des finalen Modells somit um ca. 0,89 Tore pro Team und Spiel von den tatsächlich erzielten Toren ab. Der ebenfalls geringere RMSE weist zudem darauf hin, dass auch Spiele in denen überdurchschnittlich viele Tore fallen, besser durch das Modell vorhergesagt werden können.

Ein weiteres Maß zur Beurteilung der Modellgüte stellt die Bestimmung des Anteils korrekt vorhergesagter Spielausgänge dar. Dazu wurden zunächst für jedes Spiel die vorhergesagten Tore beider Teams aus dem Modell übernommen und daraus durch Vergleich von Heim- und Auswärtstoren der prognostizierte Spielausgang abgeleitet. Anschließend wurde dieser prognostizierte Spielausgang mit dem tatsächlich beobachteten Ergebnis verglichen. Die *Accuracy* entspricht dem Anteil der Spiele, in denen vorhergesagter und tatsächlicher Spielausgang übereinstimmen. Als Baselines wurden zwei einfache Vorhersagen erstellt. Zum einen wurde für jedes Spiel ein Heimsieg prognostiziert, da dieser im Testdatensatz den häufigsten Spielausgang darstellte. Zum anderen wurde jeweils das Team mit dem höheren Marktwert als Sieger vorhergesagt.

Tabelle 4 zeigt, dass das finale Modell 53,85 % der Spielausgänge korrekt vorhersagt. Es übertrifft damit sowohl die Heimsieg-Baseline von 45,21 % als auch die

| Modell             | Accuracy       |
|--------------------|----------------|
| Heimsieg-Baseline  | 45,21 %        |
| Marktwert-Baseline | 49,95 %        |
| Finales Modell     | <b>53,85 %</b> |

Tabelle 4: Anteil korrekt vorhergesagter Spielausgänge im Testdatensatz.

Marktwert-Baseline von 49,95 %.

Frühere Modelle beinhalteten den Ansatz zur fairen Variablenselektion für nicht-lineare und lineare Prädiktoren, bei dem darauf geachtet wird, dass konkurrierende Basislerner hinsichtlich ihrer Flexibilität vergleichbar sind. Andernfalls kann es zu einem Selektionsbias kommen, da flexiblere Basislerner systematisch bevorzugt werden, unabhängig von ihrem tatsächlichen Zusammenhang mit der Zielvariable. Zur Vermeidung dieses Bias wird vorgeschlagen, allen Basislernern vergleichbare Freiheitsgrade zuzuweisen, sodass eine unverzerrte Variablenselektion ermöglicht wird (Hofner et al., 2011). Obwohl der Ansatz der fairen Variablenselektion verwendet wurde, wurden in den entsprechenden Modellen ausschließlich lineare Basislerner ausgewählt. Außerdem ergab sich eine geringere optimale Stoppiteration sowie eine schlechtere Vorhersagegüte als im rein linearen Modell. Da die nichtlinearen Basislerner somit nicht zur Reduzierung des Vorhersagefehlers beitrugen, wurden sie für das finale Modell ausgeschlossen <sup>1</sup>.

---

<sup>1</sup>Dies kann im beigelegten R-Skript "HofnerApproach.R" nachvollzogen werden.



## 5 Diskussion

### 5.1 Inhaltliche Interpretation der Ergebnisse

Zur inhaltlichen Interpretation lassen sich die ausgewählten Variablen vor allem den Bereichen Mittelfeld- und Offensivqualität, Spielkontrolle sowie Spielkontext zuordnen. Die Korrelationsmatrix der im finalen Modell berücksichtigten Variablen im Anhang (vgl. Abschnitt 7.10) zeigt zugleich, dass diese Bereiche teilweise eng miteinander verbunden sind.

Am häufigsten wurden Variablen ausgewählt, die auf relative Qualitätsvorteile im Mittelfeld hinweisen. Hierzu zählen Bewertungs- und Marktwertverhältnisse sowie Maße zur Verfügbarkeit gegnerischer Mittelfeldspieler. Den zweitwichtigsten Bereich bilden Merkmale der Offensivqualität, vor allem im Verhältnis zur gegnerischen Defensive und zum Torwart, ergänzt durch negative Effekte fehlender Offensivspieler. Einen weiteren zentralen Einflussfaktor stellt die Hauptkomponente *Spielkontrolle* dar, die sowohl direkt als Differenz und auch in Kombination mit der Hauptkomponente der *Torwartstärke* in das Modell eingeht. Ergänzt wird dieses Muster durch Variablen des Spielkontexts wie Formdifferenz, Heimvorteil und *Defensivintensität*.

Insgesamt deutet das Modell darauf hin, dass vor allem die Qualität des Mittelfelds und der Offensivspieler sowie eine starke Ausprägung der *Spielkontrolle* die erwartete Toranzahl prägen. Diese Einflussfaktoren wirken dabei nicht isoliert, sondern sind eng miteinander verbunden. Dies zeigt sich in der Korrelation zwischen den Variablen der *Spielkontrolle* sowie den Qualitätsmaßen des Mittelfelds und der Offensivspieler. Dies erscheint aus fußballerischer Sicht nachvollziehbar, da ein qualitativ stark besetztes Mittelfeld häufig mit mehr Kontrolle über das Spielgeschehen einhergeht und zugleich die Grundlage für gefährliche Offensivaktionen schafft. Darüber hinaus korreliert die *Spielkontrolle* deutlich mit der Formdifferenz, was darauf hindeutet, dass formstärkere Teams das Spiel häufiger kontrollieren. Das erfolgreiche Teams über eine höhere *Spielkontrolle* verfügen, war bereits in der deskriptiven Betrachtung der Hauptkomponenten erkennbar und wird durch das finale Modell gestützt. Insgesamt spricht dies dafür, dass relative Qualitätsvorteile, insbesondere im Mittelfeld und Offensivbereich, mit einer starken Ausprägung der *Spielkontrolle* verbunden sind und sich im Modell in einer höheren Torerwartung widerspiegeln.

Die Ergebnisse zeigen, dass das finale Modell die erzielte Toranzahl pro Team präziser vorhersagt als die Mittelwert-Baseline. Auch die aus den Torvorhersagen abgeleitete Prognose des Spielausgangs übertrifft sowohl die Heimsieg- als auch die

Marktwert-Baseline. Dies deutet darauf hin, dass die vor dem Spiel verfügbaren Modellinformationen einen relevanten Beitrag zur Erklärung der Torproduktion leisten. Zugleich bleibt die Vorhersagegüte moderat, was darauf schließen lässt, dass die Torerzielung im Fußball weiterhin von situativen, nur schwer beobachtbaren und zufallsbedingten Einflüssen geprägt ist, die selbst unter Einbezug fixer und zufälliger Effekte nicht vollständig erklärt werden können.

## 5.2 Bewertung der konstruierten Variablen

Die auf Basis der Post-Match-Statistiken konstruierten Hauptkomponenten erwiesen sich als wichtiger Bestandteil der vorliegenden Analyse. Durch sie konnten zahlreiche korrelierte Spielberichtsvariablen zu wenigen interpretierbaren Spielstil-Dimensionen zusammengefasst werden, die sowohl für die Modellierung als auch für die inhaltliche Einordnung der Mannschaften genutzt wurden. Für das finale Prognosemodell wurden nur Variablen mit Bezug zu den Hauptkomponenten *Spielkontrolle* und *Defensivintensität* ausgewählt. Dies ist nicht überraschend, da diese Komponenten den größten Anteil der Gesamtvarianz der Spielberichtsvariablen erklären. Zugleich deutet dieses Ergebnis darauf hin, dass vor allem diese beiden Dimensionen auch für die Vorhersage der Toranzahl relevant sind, während andere Hauptkomponenten zwar zur Beschreibung von Spielstilen beitragen, aber nur begrenzt für direkte Vergleiche zwischen Teams geeignet sind.

Darüber hinaus zeigte sich, dass die PCA auch unabhängig vom finalen Modell einen analytischen Mehrwert bietet. Insbesondere die grafische Gegenüberstellung von Teams anhand der ersten Hauptkomponenten ermöglichte eine Veranschulichung unterschiedlicher Mannschaftsprofile und machte Unterschiede zwischen erfolgreichen, durchschnittlichen und schwächeren Teams sichtbar. Einschränkend ist allerdings zu berücksichtigen, dass sich nicht alle Hauptkomponenten in gleicher Weise für einen direkten inhaltlichen Vergleich eignen, da ihre Interpretation zum Teil weniger eindeutig ausfällt und sie häufig mehrere spielerische Aspekte gleichzeitig abbilden.

Die Variablen zur Erfassung fehlender Schlüsselspieler tauchen im finalen Modell zwar ebenfalls auf und sind inhaltlich plausibel interpretierbar, ihr zusätzlicher Beitrag fällt jedoch eher gering aus. Eine mögliche Erklärung hierfür ist, dass die Konstruktion dieser Variablen eng an die Bildung der PCA-basierten Variablen angelehnt ist, da in beiden Fällen Informationen aus den vergangenen Spielen berücksichtigt werden. Es liegt daher nahe, dass die PCA bereits einen Teil der Effekte erfasst,

die durch das Fehlen von Schlüsselspielern entstehen. Vor diesem Hintergrund erscheint der zusätzliche Nutzen der Schlüsselspieler-Variablen im Verhältnis zum Konstruktionsaufwand eher begrenzt. Hinzu kommt, dass die Identifikation von Schlüsselspielern auf Basis gespielter Minuten methodisch anspruchsvoll ist, da sie zahlreiche Annahmen erfordert, beispielsweise darüber, wie Neuzugänge in die Hierarchie des bestehenden Kaders integriert werden. Dies zeigte sich bereits bei der Konstruktion dieser Variablen.

### 5.3 Einordnung der Ergebnisse im Vergleich zur Literatur

Während die bisherige Diskussion der Ergebnisse vor allem die inhaltliche Plausibilität der selektierten Variablen unterstreicht, ist im nächsten Schritt zu prüfen, wie sich die Vorhersagegüte des Modells im Vergleich zu bestehenden Arbeiten einordnen lässt. Herbinet (2018) untersucht verschiedene Regressions- und Klassifikationsmodelle zur Vorhersage von Spielständen und Spielausgängen auf Basis eines umfangreichen Datensatzes aus mehreren europäischen Ligen, während Forcher et al. (2025) für die Bundesliga Pre- und Post-Match-Modelle zur Prognose von Spielausgängen auf Grundlage von erwarteten Toren (xG) und Expected Possession Value (EPV) entwickeln.

Im Vergleich zu Herbinet zeigt sich, dass die Torprognose des vorliegenden Modells hinsichtlich RMSE und MAE auf einem ähnlichen Niveau liegt. Herbinet berichtet für sein finales Regressionsmodell einen RMSE von 1,153 und einen MAE von 0,861, zudem erreicht seine aus den Torvorhersagen abgeleitete Spielausgangsprognose eine Accuracy von 44,6 %, während sein finales Klassifikationsmodell auf 51,1 % kommt. Die vorliegende Arbeit erzielt demgegenüber einen RMSE von 1,156, einen MAE von 0,891 und eine Accuracy von 53,85 %. Damit liegt die Torprognose nah an den Ergebnissen von Herbinet, während die aus den Torvorhersagen abgeleitete Accuracy sowohl seine regressionsbasierte als auch seine klassifikationsbasierte Vorhersage übertrifft. Dabei ist zu beachten, dass Herbinet seine Modelle nicht auf einer späteren Saison testet. Stattdessen werden die vorhandenen Daten aus den Saisons 2014/2015 und 2015/2016 mehrfach intern in Trainings- und Testteile aufgeteilt und per Cross-Validation ausgewertet.

Gegenüber Forcher et al. (2025) fällt der Vergleich differenzierter aus. Für das dort berichtete xG-Pre-Match-Modell mit Random Forest werden ein MAE von 0,934 und ein RMSE von 1,182 ausgewiesen. Hinsichtlich der Spielausgangsprognose erreicht das beste xG-Pre-Match-Modell eine Accuracy von 55,6 %, während das

beste EPV-Pre-Match-Modell eine Accuracy von 58,3 % erzielt. Das beste Post-Match-Modell der Studie erreicht eine Accuracy von 65,6 %. Die Accuracy des vorliegenden Modells liegt damit über dem xG-basierten Pre-Match-Ergebnis von Forcher et al., jedoch unter deren bestem EPV-Pre-Match- sowie dem besten Post-Match-Ergebnis. Die Vergleichbarkeit ist jedoch eingeschränkt, da Forcher et al. ausschließlich Bundesliga-Daten aus drei Saisons verwenden, zusätzlich auf Event- und Trackingdaten sowie auf probabilistische Spielausgangsprognosen zurückgreifen und ihre Pre-Match-Modelle ebenfalls nicht auf einer vollständig zukünftigen Saison evaluieren. Während im vorliegenden Fall zunächst die Toranzahl pro Team modelliert und daraus anschließend der Spielausgang abgeleitet wird, werden bei Forcher et al. Wahrscheinlichkeiten für Spielausgänge direkt aus den jeweiligen Modellansätzen bestimmt. Vor diesem Hintergrund können die Ergebnisse des vorliegenden Modells insgesamt als konkurrenzfähig eingeordnet werden. Dies gilt insbesondere deshalb, weil die Modellgüte in der vorliegenden Arbeit auf einer vollständigen späteren Saison überprüft wird und damit unter prognosenäheren Bedingungen beurteilt wird als in den herangezogenen Vergleichsstudien.

Die Befunde von Forcher et al. stützen die Ergebnisse der vorliegenden Arbeit insofern, als sie ebenfalls darauf hindeuten, dass für die Prognose zukünftiger Spielverläufe nicht nur Abschlusssituationen, sondern auch Merkmale der Spielkontrolle und Angriffsqualität relevant sind. So argumentieren die Autoren, dass EPV im Pre-Match-Bereich gegenüber xG im Vorteil ist, weil dieser Ansatz Angriffssequenzen und Ballbesitzphasen umfassender abbildet. Dies passt konzeptionell zu dem Ergebnis, dass in der vorliegenden Arbeit die Hauptkomponente *Spielkontrolle* zu den relevanten Einflussfaktoren zählt.

## 5.4 Limitationen und Ausblick

Trotz der insgesamt konkurrenzfähigen Ergebnisse unterliegt die vorliegende Arbeit mehreren Einschränkungen. Eine Limitation besteht darin, dass zeitliche Dynamiken in der eigentlichen Modellierung nur indirekt berücksichtigt werden. Zwar gehen mit Formdifferenzen sowie den auf den letzten Spielen basierenden PCA-Variablen Informationen zur jüngeren Leistungsentwicklung in das Modell ein, der Zeitpunkt eines Spiels innerhalb einer Saison wird jedoch nicht explizit modelliert. Damit bleiben Anpassungen der Saisonziele, beispielsweise durch das Ausscheiden in Pokalwettbewerben, Brüche des Spielrhythmus durch Transferphasen, oder eine plötzliche Formsteigerung durch einen Trainerwechsel nur unvollständig erfasst. Diese Beispi-

le verdeutlichen, dass Veränderungen des Leistungsniveaus im Fußball nicht immer kontinuierlich verlaufen, sondern oft auch sprunghaft stattfinden, was eine zeitliche Modellierung anspruchsvoll macht.

Darüber hinaus ist die Vergleichbarkeit der Teams und Ligen nicht vollständig frei von Einschränkungen. Die gemeinsame Modellierung der Top-5-Ligen setzt implizit voraus, dass die konstruierten Variablen in allen Wettbewerben in ähnlicher Weise interpretierbar sind. Tatsächlich ist jedoch denkbar, dass sich Spielstile, Spielerbelastung und Erfolgsfaktoren zwischen den Ligen systematisch unterscheiden.

Aus diesen Limitationen ergeben sich mehrere Ansatzpunkte für zukünftige Arbeiten. Ein naheliegender Schritt besteht darin, die Tor- und Spielausgangsvorhersage miteinander zu verknüpfen. Anstelle der Ableitung des Spielausgangs aus der Torprognose könnte künftig auch die Tordifferenz direkt modelliert werden, wie Karlis and Ntzoufras (2009) bereits für Fußballergebnisse auf Basis der Skellam-Verteilung gezeigt haben.

Ein weiterer Ausblick betrifft die PCA-basierte Abbildung von Spielstilen. Da sich die europäischen Topligen in ihren Spielweisen unterscheiden könnten, wäre es sinnvoll, Hauptkomponenten künftig liga-spezifisch zu konstruieren, um solche Charakteristika präziser zu erfassen. Erste Studien deuten tatsächlich darauf hin, dass sich zwischen den großen europäischen Ligen signifikante Unterschiede in den Spielstilen zeigen (Chacoma and Billoni, 2025).

## 6 Fazit

Ziel der vorliegenden Arbeit war es, zu untersuchen, inwieweit sich die erzielte Toranzahl pro Team in den europäischen Top-5-Ligen auf Basis vor Spielbeginn verfügbarer Informationen für eine spätere Saison prognostizieren lässt und ob PCA-basierte Indikatoren taktischer Spielstile hierzu einen Beitrag leisten können. Die Ergebnisse zeigen, dass eine solche Torprognose mit angemessener Vorhersagegüte möglich ist. Zugleich erhöht die zeitliche Trennung von Training und Test die Aussagekraft der Analyse, da die Modellgüte unter realitätsnäheren Prognosebedingungen beurteilt wird.

Ein wesentlicher Bestandteil der Arbeit war die Konstruktion von Spielstilindikatoren auf Grundlage umfangreicher Spielberichtsstatistiken. Die Hauptkomponentenanalyse ermöglichte dabei nicht nur eine Verdichtung der hohen Zahl korrelierter Variablen, sondern lieferte auch inhaltlich interpretierbare Dimensionen des Spielstils. Vor allem die Hauptkomponente *Spielkontrolle* erwies sich sowohl in der deskriptiven Analyse als auch im finalen Modell als relevant. Weitere relevante Einflussfaktoren waren Variablen zur Mittelfeld- und Offensivqualität, der Heimvorteil sowie der Formunterschied.

Die insgesamt nur moderate Vorhersagegüte macht jedoch deutlich, dass die Torerzielung im Fußball weiterhin in erheblichem Maße durch situative und zufallsbedingte Einflüsse geprägt ist, die durch die vor Spielbeginn verfügbaren Informationen nicht vollständig erfasst werden können. Weiteres Potenzial besteht insbesondere in einer stärkeren Berücksichtigung zeitlicher Dynamiken, einer engeren Verknüpfung von Tor- und Spielausgangsprognosen sowie in einer liga-spezifischen Konstruktion der Spielstilindikatoren.

## Literaturverzeichnis

- Peter Bühlmann and Torsten Hothorn. Boosting algorithms: Regularization, prediction and model fitting. *Statistical Science*, 22(4):477–505, 2007. doi: 10.1214/07-STS242.
- Peter Bühlmann and Bin Yu. Boosting with the l2 loss: Regression and classification. *Journal of the American Statistical Association*, 98(462):324–339, 2003. doi: 10.1198/016214503000125.
- Andrés Alberto Chacoma and Orlando Vito Billoni. Data-driven approach to defining football styles in major leagues. *Chaos, Solitons & Fractals*, 200:116926, 2025. doi: 10.1016/j.chaos.2025.116926.
- Mark J. Dixon and Stuart G. Coles. Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 46(2):265–280, 1997. doi: 10.1111/1467-9876.00065.
- Brian S. Everitt and Torsten Hothorn. *An Introduction to Applied Multivariate Analysis with R*. Springer, New York, 2011. doi: 10.1007/978-1-4419-9650-3.
- Ludwig Fahrmeir, Thomas Kneib, Stefan Lang, and Brian Marx. *Regression: Models, Methods and Applications*. Springer, 2009.
- FBref. Fbref: Soccer statistics and historical results, 2026. URL <https://fbref.com/>.
- FIFA. The football landscape – the vision 2020–2023. FIFA Publications, 2021.
- Leander Forcher, Leon Forcher, Alexander Woll, and Stefan Altmann. Ai in bundesliga match analysis—expected possession value (epv) vs. expected goals (xg) to predict match outcomes in soccer. *Frontiers in Sports and Active Living*, 7: 1713852, 2025. doi: 10.3389/fspor.2025.1713852.
- Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001. doi: 10.1214/aos/1013203451.
- Colin Griesbach, Andreas Groll, and Elisabeth Bergherr. Addressing cluster-constant covariates in mixed effects models via likelihood-based boosting techniques. *PLoS ONE*, 16(7):e0254178, 2021. doi: 10.1371/journal.pone.0254178.

- Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2009.
- Corentin Herbinet. Predicting football results using machine learning techniques, 2018. Undergraduate project report.
- Benjamin Hofner, Torsten Hothorn, Thomas Kneib, and Matthias Schmid. A framework for unbiased model selection based on boosting. *Journal of Computational and Graphical Statistics*, 20(4):956–971, 2011. doi: 10.1198/jcgs.2011.09220.
- Ondřej Hubáček, Gustav Šourek, and Filip Železný. Forty years of score-based soccer match outcome prediction: An experimental review. *IMA Journal of Management Mathematics*, 33(1):1–18, 2022. doi: 10.1093/imaman/dpab029.
- Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, 2021.
- Dimitris Karlis and Ioannis Ntzoufras. Bayesian modelling of football outcomes: Using the skellam distribution for the goal difference. *IMA Journal of Management Mathematics*, 20(2):133–145, 2009. doi: 10.1093/imaman/dpn026.
- Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 2012. doi: 10.1145/2382577.2382579.
- Lars Kneiper, Torsten Hothorn, Elisabeth Bergherr, and Colin Griesbach. Gradient boosting for generalised additive mixed models. *Statistics and Computing*, 35:84, 2025. doi: 10.1007/s11222-025-10612-y.
- Andreas Mayr, Benjamin Hofner, and Matthias Schmid. The importance of knowing when to stop: A sequential stopping rule for component-wise gradient boosting. *Methods of Information in Medicine*, 51(2):178–186, 2012. doi: 10.3414/ME11-02-0030.
- Andreas Mayr, Harald Binder, Olaf Gefeller, and Matthias Schmid. The evolution of boosting algorithms. *Methods of Information in Medicine*, 53(6):419–427, 2014. doi: 10.3414/ME14-01-0042. URL <https://doi.org/10.3414/ME14-01-0042>.
- Assaf Rabinowicz and Saharon Rosset. Cross-validation for correlated data. *Journal of the American Statistical Association*, 117(538):718–731, 2022. doi: 10.1080/01621459.2020.1801451.



- David R. Roberts, Volker Bahn, Simone Ciuti, Mark S. Boyce, Jane Elith, Gurutzeta Guillera-Arroita, Severin Hauenstein, José J. Lahoz-Monfort, Boris Schröder, Wilfried Thuiller, David I. Warton, Brendan A. Wintle, Florian Hartig, and Carsten F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017. doi: 10.1111/ecog.02881.
- Janek Thomas, Tobias Hepp, Andreas Mayr, and Bernd Bischl. Probing for sparse and fast variable selection with model-based boosting. *Computational and Mathematical Methods in Medicine*, 2017:1421409, 2017. doi: 10.1155/2017/1421409.
- Transfermarkt GmbH & Co. KG. Transfermarkt – das fußball-portal mit transfers, marktwerten, gerüchten und statistiken, 2026. URL <https://www.transfermarkt.de/>.
- Fabian Wunderlich, Alessandro Seck, and Daniel Memmert. The influence of randomness on goals in football decreases over time: An empirical analysis of randomness involved in goal scoring in the english premier league. *Journal of Sports Sciences*, 39(20):2322–2337, 2021. doi: 10.1080/02640414.2021.1930685.

## 7 Anhang

### 7.1 Spielerwerte (EA Sports FC)

| Leistungskennzahlen |
|---------------------|
| Gesamtbewertung     |
| Paraden             |
| Ballsicherheit      |
| Abschläge           |
| Stellungsspiel      |
| Reflexe             |
| Tempo               |

Tabelle 5: Torhüter

| Leistungskennzahlen |
|---------------------|
| Gesamtbewertung     |
| Tempo               |
| Abschluss           |
| Passspiel           |
| Dribbling           |
| Verteidigen         |
| Physis              |

Tabelle 6: Feldspieler

### 7.2 Übersicht der Skill-Matchups

| Matchup-Typ                             | Konstruktion                                                                                                       |
|-----------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| Angriff vs. Abwehr                      | $\log \left( \frac{\text{Abschluss (Angriff)}}{\text{Verteidigen (gegnerische Abwehr)}} \right)$                   |
| Angriff vs. Torwart                     | $\log \left( \frac{\text{Abschluss (Angriff)}}{\text{Reflexe (gegnerischer Torwart)}} \right)$                     |
| Mittelfeld vs. Mittelfeld               | $\log \left( \frac{\text{Gesamtbewertung (Mittelfeld)}}{\text{Gesamtbewertung (gegnerisches Mittelfeld)}} \right)$ |
| Mittelfeld vs. Abwehr                   | $\log \left( \frac{\text{Passspiel (Mittelfeld)}}{\text{Verteidigen (gegnerische Abwehr)}} \right)$                |
| Angriff (Tempo) vs. Abwehr (Tempo)      | $\log \left( \frac{\text{Tempo (Angriff)}}{\text{Tempo (gegnerische Abwehr)}} \right)$                             |
| Angriff (Dribbling) vs. Abwehr (Physis) | $\log \left( \frac{\text{Dribbling (Angriff)}}{\text{Physis (gegnerische Abwehr)}} \right)$                        |

Tabelle 7: Ausschnitt der konstruierten Log-Ratio-Matchups

### 7.3 Beobachtete Formationen




Abbildung 7: Verteilung der beobachteten Formationen. Die Abbildung zeigt die Häufigkeitsverteilung der im Datensatz vorkommenden Formationen. Die Formationen 4-2-3-1, 4-3-3 und 4-4-2 bilden den Großteil der beobachteten Formationen, während andere Formationen deutlich seltener auftreten.

## 7.4 FBref: Matchstatistiken

| Kategorie                 | Variablen                                                                                           |
|---------------------------|-----------------------------------------------------------------------------------------------------|
| <b>Abschluss</b>          | Sh, SoT, SoT%, G/Sh, G/SoT, Dist, FK, PK, PKatt, xG, npxG, npxG/Sh, G-xG, np:G-xG                   |
| <b>Torwart</b>            | SoTA, Saves, Save%, CS, PSxG, PSxG+/-, PKatt, PKA, PKsv, PKm                                        |
| <b>Passspiel</b>          | Cmp, Att, Cmp%, TotDist, PrgDist, Short_Cmp, Short_Att, Medium_Cmp, Medium_Att, Long_Cmp, Long_Att  |
| <b>Kreativität</b>        | Ast, xAG, xA, KP, FinalThird, PPA, CrsPA, PrgP                                                      |
| <b>Defensive Aktionen</b> | Tkl, TklW, Def3rd, Mid3rd, Att3rd, Challenges_Tkl, Challenges_Att, Challenges_Tkl%, Challenges_Lost |
| <b>Defensivintervent.</b> | Blocks, Blocks_Sh, Blocks_Pass, Int, Tkl+Int, Clr, Err                                              |
| <b>Ballbesitz</b>         | Poss, Touches, DefPen, Def3rd, Mid3rd, Att3rd, AttPen, Live                                         |
| <b>Dribbling</b>          | Att, Succ, Succ%, Tkld, Tkld%                                                                       |
| <b>Ballführen</b>         | Carries, TotDist, PrgDist, PrgC, FinalThird, CPA, Mis, Dis                                          |
| <b>Sonstiges</b>          | CrdY, CrdR, Fls, Fld, Off, Crs, PKwon, PKcon, OG, Recov                                             |

Tabelle 8: Übersicht der für die PCA verwendeten Matchstatistiken

## 7.5 Hauptkomponenten und Variablenladungen

Die Bezeichnungen der Hauptkomponenten basieren auf den jeweils dominierenden Variablenladungen und stellen eine vereinfachende inhaltliche Interpretation dar.

Tabelle 9: Top-Loadings der Hauptkomponenten PC1 und PC2

| Variable                   | Loading | Variable                | Loading |
|----------------------------|---------|-------------------------|---------|
| passing_Total_Cmp          | -0.197  | defense_Tackles_Tkl     | 0.330   |
| passing_Total_Att          | -0.196  | defense_Tackles_TklW    | 0.312   |
| passing_Total_TotDist      | -0.194  | misc_Performance_TklW   | 0.312   |
| possession_Touches_Touches | -0.194  | defense_Tkl+Int         | 0.300   |
| possession_Touches_Live    | -0.194  | defense_Challenges_Tkl  | 0.256   |
| possession_Poss            | -0.186  | defense_Tackles_Mid 3rd | 0.239   |
| possession_Carries_Carries | -0.185  | defense_Challenges_Att  | 0.212   |
| passing_Medium_Cmp         | -0.185  | defense_Tackles_Def 3rd | 0.211   |

(a) PC1: Spielkontrolle

(b) PC2: Defensivintensität

Tabelle 10: Top-Loadings der Hauptkomponenten PC3 und PC4

| Variable               | Loading | Variable                   | Loading |
|------------------------|---------|----------------------------|---------|
| shooting_Expected_npxG | -0.256  | shooting_Standard_G/Sh     | -0.356  |
| shooting_Expected_xG   | -0.253  | shooting_Expected_G-xG     | -0.330  |
| passing_xAG            | -0.237  | shooting_Expected_np:G-xG  | -0.329  |
| shooting_Standard_SoT  | -0.197  | shooting_Standard_G/SoT    | -0.277  |
| shooting_Standard_Sh   | -0.195  | shooting_Standard_SoT%     | -0.237  |
| defense_Tackles_Tkl    | 0.195   | possession_Touches_Def 3rd | -0.206  |
| misc_Performance_TklW  | 0.185   | possession_Touches_Def Pen | -0.203  |
| defense_Tackles_TklW   | 0.185   | shooting_Expected_npxG/Sh  | -0.188  |

(a) PC3: Spielbalance

(b) PC4: Effizienz

Tabelle 11: Top-Loadings der Hauptkomponenten PC5 und PC6

| Variable                 | Loading | Variable                   | Loading |
|--------------------------|---------|----------------------------|---------|
| keeper_Performance_PSxG  | -0.334  | keeper_Performance_Save%   | 0.332   |
| keeper_Performance_SoTA  | -0.313  | keeper_Performance_PSxG+/- | 0.307   |
| misc_Aerial_Duels_Won    | 0.279   | keeper_Performance_Saves   | 0.274   |
| keeper_Performance_CS    | 0.263   | possession_Touches_Def_Pen | 0.271   |
| passing_Long_Att         | 0.237   | shooting_Expected_np:G-xG  | -0.266  |
| misc_Aerial_Duels_Lost   | 0.226   | shooting_Expected_G-xG     | -0.260  |
| defense_Challenges_Lost  | -0.210  | possession_Touches_Def_3rd | 0.248   |
| keeper_Performance_Saves | -0.183  | keeper_Performance_CS      | 0.212   |

(a) PC5: Direkttheit

(b) PC6: Torwartstärke

Tabelle 12: Top-Loadings der Hauptkomponenten PC7 und PC8

| Variable                | Loading | Variable                   | Loading |
|-------------------------|---------|----------------------------|---------|
| defense_Int             | -0.351  | keeper_Performance_CS      | 0.347   |
| misc_Performance_Int    | -0.351  | passing_Long_Att           | -0.306  |
| defense_Challenges_Tkl% | 0.277   | keeper_Performance_Save%   | 0.305   |
| misc_Performance_Recov  | -0.237  | passing_Long_Cmp           | -0.243  |
| passing_Long_Att        | 0.195   | defense_Int                | -0.235  |
| defense_Challenges_Tkl  | 0.183   | misc_Performance_Int       | -0.235  |
| passing_Long_Cmp        | 0.181   | keeper_Performance_PSxG+/- | 0.229   |
| defense_Challenges_Lost | -0.173  | keeper_Performance_PSxG    | -0.220  |

(a) PC7: Antizipation

(b) PC8: Absicherung

Tabelle 13: Top-Loadings der Hauptkomponenten PC9 und PC10

| Variable                 | Loading | Variable                   | Loading |
|--------------------------|---------|----------------------------|---------|
| defense_Int              | -0.350  | keeper_Performance_Saves   | 0.283   |
| misc_Performance_Int     | -0.350  | keeper_Performance_PSxG+/- | 0.257   |
| defense_Blocks_Blocks    | 0.325   | keeper_Performance_SoTA    | 0.232   |
| defense_Blocks_Pass      | 0.264   | keeper_Performance_Save%   | 0.217   |
| keeper_Performance_Save% | -0.203  | keeper_Performance_PSxG    | 0.204   |
| defense_Blocks_Sh        | 0.200   | misc_Aerial_Duels_Lost     | 0.198   |
| misc_Performance_2CrDY   | -0.193  | shooting_Expected_np:G-xG  | 0.186   |
| defense_Tkl+Int          | -0.189  | shooting_Expected_G-xG     | 0.183   |

(a) PC9: Blocken

(b) PC10: Torwartaktivität

## 7.6 Aufschlüsselung der Positionsgruppen

| Positionsgruppe    | Zugeordnete Positionscodes |
|--------------------|----------------------------|
| Torwart (GK)       | GK                         |
| Verteidigung (DEF) | CB, LB, RB, WB, DF         |
| Mittelfeld (MID)   | CM, DM, LM, RM, MF         |
| Angriff (ATT)      | ST, CF, FW, LW, RW, AM     |

Tabelle 14: Zuordnung der Positionscodes zu aggregierten Positionsgruppen

## 7.7 Korrelation im Datensatz




Abbildung 8: Korrelationsmatrix der numerischen Variablen des Datensatzes auf Basis paarweiser Pearson-Korrelationskoeffizienten. Die Abbildung zeigt mehrere Gruppen korrelierter Variablen.

## 7.8 Penalisierte Likelihood

**Penalisierte Log-Likelihood** (vgl. Knieper et al. (2025)) Die im mermboost-Verfahren verwendete penalisierte Log-Likelihood ergibt sich zu

$$\ell_{\text{pen}}(\boldsymbol{\theta}, \phi; y) = \sum_{i=1}^n \log(g(y_i | \boldsymbol{\theta}, \phi)) - \frac{1}{2} \sum_{i=1}^n \boldsymbol{\gamma}_i^\top \mathbf{Q}^{-1} \boldsymbol{\gamma}_i.$$

## 7.9 Zufällige Effekte




Abbildung 9: Geschätzte teambezogene Zufallseffekte für Heimspiele. Dargestellt sind die größten positiven und negativen Random-Intercept-Schätzungen  $\hat{\gamma}_{i,H}$  des finalen Modells.






Abbildung 10: Geschätzte teambezogene Zufallseffekte für Auswärtsspiele. Dargestellt sind die größten positiven und negativen Random-Intercept-Schätzungen  $\hat{\gamma}_{i,A}$  des finalen Modells.

## 7.10 Korrelationsmatrix




Abbildung 11: Korrelationsmatrix der im finalen Modell berücksichtigten Prädiktoren. Die Abbildung zeigt die paarweisen Pearson-Korrelationskoeffizienten der selektierten Kovariaten.

# Abbildungsverzeichnis

|   |                                                                                                                                                                                                                                                                                                                                             |      |
|---|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| 1 | Verteilung der erzielten Tore pro Spiel. Die Mehrheit der Beobachtungen liegt im Bereich von 0 bis 2 Toren, während höhere Toranzahlen seltener auftreten. Die rechtsschiefe Verteilung entspricht typischen Eigenschaften von Zähldaten und legt die Verwendung eines Poisson-Modells nahe. . . . .                                        | 4    |
| 2 | Erklärte und kumulierte Varianz der Hauptkomponenten. Die ersten 21 Komponenten erfassen etwa 77 % der Gesamtvarianz der verwendeten Matchstatistiken. . . . .                                                                                                                                                                              | 7    |
| 3 | Darstellung der ersten drei Hauptkomponenten für ausgewählte Teams der Saison 2019 der Top-5-Ligen Europas. Gezeigt sind jeweils der Meister (blau), ein Team aus dem Tabellenmittelfeld (rot) sowie ein Absteiger (grün). Die Projektionen der Teams im Raum der Hauptkomponenten verdeutlichen Unterschiede in ihren Spielstilen. . . . . | 8    |
| 4 | Darstellung der ersten Hauptkomponenten für ausgewählte Teams. Blaue Punkte entsprechen Heimspielen, rote Punkte Auswärtsspielen. Linien verbinden jeweils die Werte der Heim- und Auswärtsspiele eines Teams. . . . .                                                                                                                      | 11   |
| 5 | Koeffizientenpfade der im Modell berücksichtigten Variablen im Verlauf der Boosting-Iterationen. . . . .                                                                                                                                                                                                                                    | 24   |
| 6 | Geschätzte Koeffizienten der ausgewählten Variablen sowie deren Auswahlhäufigkeit im Boosting-Verfahren. . . . .                                                                                                                                                                                                                            | 25   |
| 7 | Verteilung der beobachteten Formationen. Die Abbildung zeigt die Häufigkeitsverteilung der im Datensatz vorkommenden Formationen. Die Formationen 4-2-3-1, 4-3-3 und 4-4-2 bilden den Großteil der beobachteten Formationen, während andere Formationen deutlich seltener auftreten. . . . .                                                | IX   |
| 8 | Korrelationsmatrix der numerischen Variablen des Datensatzes auf Basis paarweiser Pearson-Korrelationskoeffizienten. Die Abbildung zeigt mehrere Gruppen korrelierter Variablen. . . . .                                                                                                                                                    | XIII |
| 9 | Geschätzte teambezogene Zufallseffekte für Heimspiele. Dargestellt sind die größten positiven und negativen Random-Intercept-Schätzungen $\hat{\gamma}_{i,H}$ des finalen Modells. . . . .                                                                                                                                                  | XIV  |

|    |                                                                                                                                                                                                |     |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 10 | Geschätzte teambezogene Zufallseffekte für Auswärtsspiele. Dargestellt sind die größten positiven und negativen Random-Intercept-Schätzungen $\hat{\gamma}_{i,A}$ des finalen Modells. . . . . | XV  |
| 11 | Korrelationsmatrix der im finalen Modell berücksichtigten Prädiktoren. Die Abbildung zeigt die paarweisen Pearson-Korrelationskoeffizienten der selektierten Kovariaten. . . . .               | XVI |

## Erklärung zur guten wissenschaftlichen Praxis

Hiermit erkläre ich rechtsverbindlich, dass ich die vorliegende Arbeit selbstständig angefertigt, keine anderen als die angegebenen Hilfsmittel benutzt und die Stellen der Arbeit, die im Wortlaut (zitiert) oder wesentlichen Inhalt (paraphrasiert) aus anderen Werken übernommen wurden, mit genauer Quellenangabe kenntlich gemacht habe.

Mir ist bekannt, dass Plagiate, zu denen auch ungekennzeichnete Kopien aus dem Internet gehören, nicht nur wissenschaftlich unredlich sind und den Richtlinien der Georg-August-Universität Göttingen zur Sicherung guter wissenschaftlicher Praxis vom 5. Juni 2002 widersprechen, sondern auch erhebliche rechtliche Folgen bis hin zum Ausschluss von der Universität haben können. Ich erkläre mich mit der Prüfung dieser Arbeit durch ein Plagiatsprüfungsprogramm einverstanden.

Ort und Datum

Unterschrift

Rosdorf, 20.04.2026

---

Niklas Rappe

---

# Erklärung zur Nutzung von ChatGPT und vergleichbaren Werkzeugen im Rahmen von Prüfungen

In der hier vorliegenden Arbeit habe ich ChatGPT oder eine andere KI wie folgt genutzt:

- ☐ gar nicht
- ☐ bei der Ideenfindung
- ☐ bei der Erstellung der Gliederung
- ☐ zum Erstellen einzelner Passagen, insgesamt im Umfang von \_\_\_\_\_% am gesamten Text
- ☒ zum Korrekturlesen oder Optimieren und Übersetzen des Texts
- ☒ zum Erstellen, Überarbeiten und Debuggen von Programmcode
- ☐ Weiteres, nämlich: \_\_\_\_\_

Ich versichere, alle Nutzungen vollständig angegeben zu haben. Fehlende oder fehlerhafte Angaben werden als Täuschungsversuch gewertet.

Ort und Datum

Unterschrift

Rosdorf, 20.04.2026

Niklas Rappe

---

---